รายงานผู้เชี่ยวชาญ: ความเป็นไปได้และความท้าทายของการแปลภาษาบาลีเป็นภาษาไทยโดยใช้แบบจำลองภาษาขนาดใหญ่ (LLMs)

I. บทสรุปสำหรับผู้บริหาร: สถานะปัจจุบันและข้อค้นพบหลัก

จากการวิเคราะห์อย่างละเอียดเกี่ยวกับสถานะของแบบจำลองภาษาขนาดใหญ่ (LLMs) ทั่วโลก พบว่าปัจจุบันยังไม่มี LLM เฉพาะทางที่มีความแม่นยำสูงและเข้าถึงได้สาธารณะสำหรับการแปลภาษาบาลีเป็นภาษาไทยในระดับประโยคที่ซับซ้อน **ข้อสรุปหลักคือเทคโนโลยีสำหรับการแปลภาษาบาลีโดย LLM นั้นยังอยู่ในช่วงของการวิจัยและการประยุกต์ใช้เริ่มต้นเท่านั้น**

แบบจำลองอเนกประสงค์ขนาดใหญ่ (เช่น GPT-4 หรือ Gemini) สามารถลองแปลงานนี้ได้ผ่านความสามารถแบบ Zero-Shot (การแปลโดยไม่มีการฝึกฝนเฉพาะทาง) อย่างไรก็ตาม ความแม่นยำจะลดลงอย่างมากเมื่อเผชิญกับข้อความบาลีที่มีความซับซ้อนทางไวยากรณ์หรือต้องอาศัยความรู้เชิงลึกเฉพาะทาง

อุปสรรคสำคัญที่สุด คือการขาดแคลนชุดข้อมูลคู่ขนาน (Parallel Corpus) ภาษาไทย-ภาษาบาลีที่มีขนาดใหญ่ สะอาด และเผยแพร่สู่สาธารณะเพื่อใช้ในการฝึกฝนโมเดล ชุดข้อมูลคู่ขนานที่มีศักยภาพสูงสุดสำหรับการพัฒนา LLM สำหรับงานนี้คือพระไตรปิฎกฉบับภาษาบาลีและฉบับแปลภาษาไทย ซึ่งเป็นผลงานที่เกิดจากโครงการของสถาบันการศึกษาในประเทศ (เช่น โครงการ MCUTRAI ของมหาวิทยาลัยมหาจุฬาลงกรณราชวิทยาลัย) หากข้อมูลพื้นฐานเหล่านี้ได้รับการปลดล็อก จัดทำความสะอาด และจัดเรียงให้เป็นมาตรฐานเชิงคำนวณ ถือเป็นปัจจัยสำคัญที่สุดที่จะนำไปสู่การพัฒนา LLM ภาษาไทย-บาลีที่มีประสิทธิภาพในอนาคต

II. บทนำสู่ภูมิทัศน์ทางภาษาศาสตร์และคอมพิวเตอร์

2.1 การกำหนดขอบเขตการวิจัย: ความไม่สมมาตรของภาษาไทยและภาษาบาลี

งานแปลระหว่างภาษาไทยและภาษาบาลีนำมาซึ่งความท้าทายเชิงโครงสร้างที่ซับซ้อน เนื่องจากภาษาทั้งสองจัดอยู่ในตระกูลภาษาและมีโครงสร้างทางไวยากรณ์ที่แตกต่างกันอย่างมาก

- **ภาษาไทย (Thai):** เป็นภาษาสมัยใหม่ จัดเป็นภาษาโดดเดี่ยว (Analytic or Isolating Language) ซึ่งโครงสร้างทางไวยากรณ์ส่วนใหญ่ไม่ขึ้นอยู่กับการผันคำ (Inflection) และมีทรัพยากรดิจิทัลที่ค่อนข้างแข็งแกร่ง แม้ว่าชุดข้อมูลคู่ขนานภาษาไทยกับภาษาอื่น ๆ จะยังขาดแคลนเมื่อเทียบกับภาษาระดับสูง (High-Resource Languages) เช่น อังกฤษ
- **ภาษาบาลี (Pali):** เป็นภาษากลุ่มอินโด-อารยันยุคกลาง (Middle Indo-Aryan) เป็นภาษาคลาสสิกที่มีการผันคำสูง (Highly Inflected) และเป็นภาษาสังเคราะห์ (Synthetic Language) โครงสร้างทางภาษาที่ซับซ้อนนี้จำกัดการใช้งานหลักอยู่ในบริบททางศาสนาและวิชาการ ทำให้ปริมาณของข้อความที่ทันสมัยและหลากหลายสำหรับการฝึกฝนโมเดลมีน้อยมาก

2.2 บทบาทของภาษาบาลีในมนุษยศาสตร์ดิจิทัลและพระพุทธศาสนาเถรวาท

ภาษาบาลีเป็นภาษาที่ใช้บันทึกพระไตรปิฎก (Pali Canon) ซึ่งเป็นคัมภีร์หลักของพระพุทธศาสนาเถรวาท ความแม่นยำในการแปลจึงมีความสำคัญอย่างยิ่งต่อการศึกษาทางวิชาการและการปฏิบัติทางศาสนา ความจำเป็นในการแปลและการสืบค้นพระไตรปิฎกนี้เองที่เป็นแรงผลักดันให้สถาบันทางศาสนาและวิชาการในประเทศไทย (เช่น มหาวิทยาลัยมหาจุฬาลงกรณราชวิทยาลัย) ดำเนินการโครงการการแปลและจัดทำดิจิทัลมาอย่างต่อเนื่อง ซึ่งเป็นการยืนยันถึงมูลค่าอันสูงยิ่งของภาษาบาลีในบริบทดิจิทัล

2.3 ปัญหาของภาษาที่มีทรัพยากรต่ำ (Low-Resource Language) ใน NLP

การพัฒนา LLM เพื่อการแปลภาษาที่มีประสิทธิภาพสูงจำเป็นต้องใช้ชุดข้อมูลข้อความที่มีการจัดเรียง (Aligned Text) จำนวนมหาศาล หรือที่เรียกว่าชุดข้อมูลคู่ขนาน (Parallel Corpora) ภาษาในเอเชียตะวันออกเฉียงใต้ รวมถึงภาษาไทยและภาษาเวียดนาม ถูกจัดอยู่ในกลุ่มภาษาที่ขาดแคลนชุดข้อมูลคู่ขนานที่สำคัญและเข้าถึงได้โดยเสรี เมื่อเทียบกับภาษาหลัก เช่น ภาษาอังกฤษ ฝรั่งเศส หรือสเปน

เมื่อปัญหาความขาดแคลนข้อมูลเกิดขึ้นกับภาษาไทยซึ่งเป็นภาษาสมัยใหม่แล้ว ปัญหานี้ยิ่งทวีความรุนแรงมากขึ้นสำหรับการแปลคู่ภาษาไทย-บาลี ซึ่งเป็นการแปลระหว่างภาษาที่ใช้ในปัจจุบันกับภาษาประวัติศาสตร์ที่มีโดเมนจำกัด (ข้อความทางศาสนาและวิชาการเท่านั้น) ปัญหานี้กำหนดให้งานพัฒนาโมเดลจำเป็นต้องอาศัยความพยายามในการดูแลจัดการข้อมูล (Human Curation) อย่างเข้มข้น และการใช้เทคนิคทางสถิติเพื่อเพิ่มข้อมูล (Data Augmentation)

III. รากฐานทางภาษาศาสตร์: อุปสรรคเชิงโครงสร้างต่อการแปลของ LLM

ความท้าทายหลักในการใช้ LLM แปลภาษาบาลีไม่ได้อยู่ที่เทคโนโลยี LLM โดยตรง แต่อยู่ที่ความซับซ้อนทางภาษาศาสตร์ของภาษาต้นทาง (Source Language) ซึ่งในกรณีนี้คือภาษาบาลี

3.1 สัณฐานวิทยาการผันคำที่ซับซ้อนและความกำกวมของคำศัพท์

ระบบการผันคำที่ซับซ้อนของภาษาบาลี ทั้งการผันวิภัตติของนาม (Case Endings) และการผันกริยา (Verb Conjugations) ก่อให้เกิดปัญหาสำคัญต่อระบบ NLP: อัตราคำนอกคลังคำศัพท์ (Out-Of-Vocabulary, OOV) สูงอย่างมาก

ภาวะวิกฤต OOV (The OOV Crisis)

แบบจำลองภาษาขนาดใหญ่สมัยใหม่มักใช้ตัวแยกคำ (Tokenizers) เช่น BPE หรือ WordPiece ซึ่งจะพยายามแบ่งคำที่ซับซ้อนออกเป็นหน่วยย่อย (Sub-word units) เพื่อจัดการกับคำ OOV อย่างมีประสิทธิภาพ แต่สำหรับภาษาบาลี การผันคำที่ซับซ้อนหมายความว่าการแบ่งคำตามกลไกของ Tokenizer ทั่วไปอาจตัดส่วนของคำออกจากส่วนลงท้ายวิภัตติที่สำคัญ ซึ่งเป็นส่วนที่ระบุบทบาททางไวยากรณ์ (เช่น การก จำนวน) ของคำนั้น การทำเช่นนี้ทำลายข้อมูลทางไวยากรณ์ที่จำเป็นก่อนที่แบบจำลอง Transformer จะสามารถประมวลผลได้ ทำให้ LLM ถูกบีบให้ต้องพึ่งพาบริบทโดยรวมเท่านั้น ซึ่งส่งผลให้ความแม่นยำในการตีความลดลงอย่างมาก

นอกจากนี้ การแปลที่เหมาะสมตามบริบทจำเป็นต้องมีการขจัดความกำกวมของคำที่มีความหมายหลายอย่าง (Polysemous words) ซึ่งมักพบในคำศัพท์ทางปรัชญาหรือศาสนา หากไม่มีความรู้เฉพาะโดเมนในระดับลึก (เช่น พุทธปรัชญา) LLM อาจไม่สามารถเลือกความหมายที่ถูกต้องตามบริบทได้

3.2 ความจำเป็นของสนธิ (Sandhi) และสมาส (Samāsa)

ภาษาบาลีใช้กฎ *สนธิ* (การเชื่อมเสียงหรือการรวมคำระหว่างคำสองคำที่อยู่ติดกัน) และ *สมาส* (การสร้างคำประสม) ซึ่งทำให้ขอบเขตของคำเดิมหายไป ข้อความบาลีที่ปรากฏในคัมภีร์จึงมักเป็นกระแสของอักขระที่ต่อเนื่องกัน โดยที่คำหลายคำถูกหลอมรวมเข้าด้วยกัน

ข้อจำกัดทางเทคนิค: LLMs ไม่สามารถเป็นระบบแบบ End-to-End ได้อย่างแท้จริง

การนำประโยคภาษาบาลีที่ยังไม่ได้แยกสนธิ (Unsplit Pali sentence) เข้าสู่ LLM โดยตรง เปรียบเสมือนการป้อนกระแสของอักขระที่ยังไม่ได้แบ่งส่วน ซึ่งแทนคำหลายคำที่รวมเข้าด้วยกัน หากไม่มีชั้นประมวลผลล่วงหน้า (Pre-processing layer) เฉพาะทาง ซึ่งก็คือ **ตัววิเคราะห์สัณฐานวิทยาของภาษาบาลี (Pali morphological analyzer)** หรือ **ตัวแยกสนธิ (Sandhi splitter)** สถาปัตยกรรม Transformer หลักจะล้มเหลวในภารกิจพื้นฐานที่สุดของการรู้จำคำ (Token recognition)

ข้อสังเกตนี้บ่งชี้ว่า LLM สำหรับภาษาไทย-บาลีที่ประสบความสำเร็จจะต้องเป็น **ระบบลูกผสม (Hybrid System)** ที่บูรณาการความเชี่ยวชาญด้าน NLP แบบดั้งเดิม (Rule-based NLP) เข้ากับเทคโนโลยีการเรียนรู้เชิงลึก (Deep Learning)

3.3 กลยุทธ์การแก้ไขของ LLM (การปรับสัณฐานวิทยา)

เพื่อรับมือกับความท้าทายนี้ มีการหารือเกี่ยวกับการใช้หน่วยย่อยของคำ (sub-word units) หรือการสร้างแบบจำลองระดับอักขระ (Character-level modeling) แทนการแยกคำแบบมาตรฐาน เพื่อจัดการกับสัณฐานวิทยาที่ซับซ้อนได้ดีขึ้น การปรับปรุงการทำ Tokenization ให้สอดคล้องกับโครงสร้างคำในภาษาบาลีเป็นขั้นตอนที่จำเป็นสำหรับการปรับปรุงประสิทธิภาพการแปล

ตารางที่ 1: ความท้าทายหลักทางภาษาศาสตร์และคอมพิวเตอร์ของการแปลภาษาบาลี

คุณสมบัติทางภาษาศาสตร์	**ผลกระทบต่อระบบ LLM/NLP**	**แนวทางแก้ไขที่จำเป็นเชิงคอมพิวเตอร์**
สัณฐานวิทยาการผันคำและการต่อเติม	อัตรา OOV สูง; ความจำเป็นในการระบุรากศัพท์ (lemmatization).	ตัววิเคราะห์/ตัวสร้างสัณฐานวิทยา (Morphological Analyzer/Generator) สำหรับการควบคุมการแยกคำ; การฝังตัวแบบระดับอักขระ (Character-level embeddings).
สนธิ (กฎการรวมเสียง)	ความกำกวมของขอบเขตคำ; การหยุดชะงักทางไวยากรณ์.	ตัวแยกสนธิแบบอิงกฎหรือสถิติ (Sandhi Splitter) (ขั้นตอนการประมวลผลล่วงหน้าภาคบังคับ).
สถานะภาษาทรัพยากรต่ำ (ข้อมูล)	การปรับจูน LLM ล้มเหลวเนื่องจากขาดตัวอย่างการฝึกฝนที่หลากหลาย.	การถ่ายโอนการเรียนรู้ (Transfer Learning) จากภาษาที่เกี่ยวข้อง (เช่น สันสกฤต/ตระกูลอินดิก); การเพิ่มข้อมูลเชิงรุก (Aggressive data augmentation).
ความเฉพาะเจาะจงของโดเมน	ความยากในการขจัดความกำกวมของคำศัพท์ทางปรัชญาหรือศาสนา.	การบูรณาการพจนานุกรม/อภิธานศัพท์เฉพาะทาง (เช่น PaliDB) เข้ากับฐานความรู้ของโมเดล.

IV. โครงสร้างพื้นฐานข้อมูล: ความขาดแคลนชุดข้อมูลคู่ขนานภาษาไทย-บาลี

ประสิทธิภาพของ LLM โดยตรงขึ้นอยู่กับคุณภาพและปริมาณของข้อมูลการฝึกฝน ในกรณีของคู่ภาษาไทย-บาลี อุปสรรคด้านข้อมูลถือเป็นข้อจำกัดที่ใหญ่ที่สุดที่ขัดขวางการสร้างโมเดลที่ใช้งานได้จริง

4.1 ช่องว่างของชุดข้อมูลคู่ขนานทั่วโลกสำหรับภาษาเอเชีย

ในระดับโลก ชุดข้อมูลคู่ขนานคุณภาพสูงสำหรับภาษาไทยนั้นมีจำกัดอยู่แล้ว โดยแตกต่างอย่างชัดเจนจากภาษาในยุโรป ชุดข้อมูลขนาดใหญ่ที่มีอยู่มักเน้นไปที่คู่ภาษาที่มีความต้องการสูง (เช่น อังกฤษ-ไทย) ในโดเมนทั่วไป (ข่าวสาร วิกิพีเดีย) งานสร้างชุดข้อมูลเหล่านี้ต้องใช้ความเชี่ยวชาญทางภาษาและความเข้าใจทางวัฒนธรรมอย่างสูง รวมถึงกระบวนการ Human-in-the-loop เพื่อรักษาความถูกต้อง

ความว่างเปล่าของข้อมูล (The Vacuum): การมุ่งเน้นไปที่คู่ภาษาสมัยใหม่และมีทรัพยากรสูง ทำให้คู่ภาษาไทย-บาลี ซึ่งเป็นภาษาเฉพาะทาง ประวัติศาสตร์ และศาสนา ถูกละเลยอย่างยิ่ง

4.2 การวิเคราะห์แหล่งข้อมูลเชิงสถาบัน: ชุดข้อมูลที่ยังไม่ได้ถูกใช้ประโยชน์

การพัฒนา LLM สำหรับการแปลภาษาบาลีเป็นภาษาไทยต้องอาศัยชุดข้อมูลคู่ขนานที่จัดเรียงไว้หลายล้านประโยค โชคดีที่ทรัพยากรพื้นฐานที่จำเป็นนี้มีอยู่แล้วในประเทศไทยผ่านความพยายามของสถาบันทางศาสนา

ความพยายามของมหาวิทยาลัยมหาจุฬาลงกรณราชวิทยาลัย (MCU)

มหาวิทยาลัยมหาจุฬาลงกรณราชวิทยาลัยได้ดำเนินการโครงการขนาดใหญ่ในการแปลและจัดทำดิจิทัลพระไตรปิฎกฉบับภาษาบาลีจำนวน 45 เล่ม ควบคู่ไปกับพระไตรปิฎกฉบับแปลภาษาไทย 45 เล่ม (โครงการ MCUTRAI) เอกสารเหล่านี้เป็นแหล่งข้อมูลคู่ขนานที่สมบูรณ์ที่สุดในโลกสำหรับคู่ภาษาไทย-บาลีในโดเมนพระพุทธศาสนา

การนำข้อมูลมาใช้ประโยชน์

การพัฒนา LLM จำเป็นต้องใช้ชุดข้อมูลหลายล้านประโยคที่จัดเรียงแล้ว ความพยายามของ MCU ในการแปลและจัดทำพระไตรปิฎกนี้ **ได้สร้างแหล่งข้อมูลนี้ขึ้นมาแล้ว** โครงการ MCUTRAI ในอดีตถูกจัดทำขึ้นบนซีดี-รอม ซึ่งบ่งชี้ว่าข้อมูลดังกล่าวมีอยู่จริง แต่มีแนวโน้มที่จะถูกเก็บไว้ในรูปแบบที่แยกส่วน ไม่ได้จัดทำดัชนี หรือจำกัดด้วยลิขสิทธิ์/รูปแบบที่ไม่เป็นมิตรต่อการประมวลผลเชิงคำนวณ

ขั้นตอนวิกฤตถัดไปสำหรับประชาคมวิจัยคือ **การปลดปล่อยข้อมูล (Data Liberation):** คือการได้รับ จัดทำความสะอาด จัดเรียง และเผยแพร่ข้อความคู่ขนานภาษาบาลี-ไทยนี้ในรูปแบบที่ใช้ฝึกฝน LLM (เช่น การทำความสะอาดจากรูปแบบไฟล์ที่ไม่เป็นมาตรฐาน) การกระทำนี้ถือเป็นตัวเร่งที่จำเป็นสำหรับความก้าวหน้าอย่างแท้จริงในการปรับจูน LLM โอเพนซอร์สที่เน้นภาษาไทย (เช่น Llama-3-Typhoon)

4.3 ความท้าทายของการดูแลจัดการและการทำคำอธิบายประกอบข้อมูล

การสร้างชุดข้อมูลคู่ขนานคุณภาพสูงสำหรับการแปลภาษาบาลีต้องอาศัยความเชี่ยวชาญด้านภาษาศาสตร์และการดูแลจัดการของมนุษย์ สำหรับภาษาบาลี ความท้าทายไม่ได้อยู่ที่การรวบรวมคำศัพท์เท่านั้น แต่ยังอยู่ที่การจัดเรียงประโยคที่ซับซ้อนและยาวมากในต้นฉบับภาษาบาลีให้ตรงกับประโยคแปลภาษาไทยที่มีเนื้อหาอธิบายเพิ่มเติมอย่างกว้างขวาง

คุณภาพและความหลากหลายของข้อมูลมีความสำคัญสูงสุดในการลดอคติและรับรองประสิทธิภาพที่แข็งแกร่งของโมเดล ข้อมูลที่ใช้ในการฝึกฝนต้องปราศจากข้อผิดพลาดในการจัดเรียง (Alignment Errors) ซึ่งอาจทำให้ LLM สับสนอย่างมากเมื่อพยายามเรียนรู้ไวยากรณ์ที่ซับซ้อน

V. การประเมินแบบจำลองภาษาขนาดใหญ่ (LLMs) สำหรับการแปลภาษาไทย-บาลี

การวิเคราะห์ความสามารถในการแปลภาษาบาลีของ LLM แบ่งออกเป็นสองกลุ่มหลัก: แบบจำลองกรรมสิทธิ์ทั่วไป และแบบจำลองโอเพนซอร์สในภูมิภาค

5.1 LLMs กรรมสิทธิ์ทั่วไป (GPT-4, Gemini): ความสามารถแบบ Zero-Shot

แบบจำลองภาษาขนาดใหญ่ที่เป็นกรรมสิทธิ์ เช่น GPT-4, แสดงให้เห็นถึงความยืดหยุ่นและความแม่นยำในการแปลที่ได้รับการปรับปรุง และสามารถเลียนแบบพฤติกรรมทางภาษาที่ซับซ้อนได้

ศักยภาพ Zero-Shot

โมเดลเหล่านี้มีฐานความรู้ทั่วไปที่กว้างขวาง และอาจมีความสามารถ "น่าประหลาดใจ" ในการแปลวลีภาษาบาลีสั้น ๆ ที่พบบ่อย โดยการจดจำรูปแบบที่เรียนรู้จากข้อความที่มีอิทธิพลสูง (เช่น ข้อมูลที่ถูกรวบรวมจากพจนานุกรมออนไลน์หรือเอกสารทางวิชาการ) นอกจากนี้ GPT-4 ยังสามารถจัดการกับงานที่ซับซ้อนได้ยืดหยุ่นกว่า GPT-3 และสามารถทำงานกับอินพุตที่เป็นรูปภาพและข้อความร่วมกันได้ ซึ่งมีประโยชน์สำหรับการประมวลผลเอกสารเก่า

ขีดจำกัดด้านประสิทธิภาพ (Performance Ceiling)

อย่างไรก็ตาม ประสิทธิภาพของโมเดลทั่วไปจะลดลงอย่างรวดเร็วเมื่อต้องจัดการกับข้อความที่ไม่เป็นไปตามรูปแบบมาตรฐาน หรือประโยคที่ยาวและซับซ้อน ซึ่งต้องอาศัยการแยกสนธิที่แม่นยำและการวิเคราะห์สัณฐานวิทยาในเชิงลึก ซึ่งเป็นสิ่งที่โมเดลเหล่านี้ขาดเครื่องมือที่สร้างขึ้นภายใน แม้แต่ LLM ขั้นสูงยังแสดงให้เห็นว่าประสิทธิภาพลดลงอย่างมีนัยสำคัญในการจัดการกับภาษาถิ่นของไทย เมื่อเทียบกับภาษาไทยมาตรฐาน ภาษาบาลีซึ่งเป็นภาษาที่มีความสัมพันธ์ทางภาษาที่ห่างไกลกว่าภาษาถิ่นมาก ย่อมเป็นอุปสรรคที่สูงกว่าอย่างเห็นได้ชัด

5.2 LLMs โอเพนซอร์สในภูมิภาค (Llama-3-Typhoon)

LLM ที่เน้นภาษาไทยโดยเฉพาะ เช่น Llama-3-Typhoon ซึ่งเป็นโมเดลภาษาขนาดใหญ่ 8 พันล้านพารามิเตอร์ที่พัฒนาต่อยอดจาก Llama3-8B ได้รับการฝึกฝนล่วงหน้าบนชุดข้อมูลภาษาไทยขนาดใหญ่ ทำให้มีความเข้าใจในภาษาไทยทั่วไปที่เหนือกว่าโมเดลอเนกประสงค์

เส้นทางการถ่ายโอนการเรียนรู้ (Transfer Learning Pathway)

โมเดลที่เน้นภาษาไทยเหล่านี้เป็นรากฐานที่เหมาะสมที่สุดสำหรับการปรับจูนเฉพาะโดเมน หากชุดข้อมูลคู่ขนานภาษาไทย-บาลีเชิงสถาบัน (ตามที่ระบุในส่วน IV) สามารถนำมาใช้งานได้ การปรับจูน Llama-3-Typhoon ด้วยข้อมูลนี้จะสร้างนักแปลเฉพาะทางที่มีคุณภาพสูงสุดอย่างเป็นไปได้

หลักฐานความยากลำบาก

ข้อเท็จจริงที่ว่างานวิจัยแสดงให้เห็นว่า LLM ระดับสูงยังคงประสบปัญหาอย่างมากกับการผันแปรภายในภาษาไทยเอง (เช่น ภาษาถิ่นอีสาน ล้านนา และด้ามโบร) เป็นการยืนยันว่าภาษาบาลีซึ่งเป็นภาษาที่แตกต่างอย่างมาก จะต้องอาศัยการปรับตัวเฉพาะโดเมนอย่างกว้างขวาง แทนที่จะพึ่งพาความสามารถทางภาษาไทยที่มีอยู่เดิมเท่านั้น

5.3 แบบจำลองเฉพาะทางวิชาการและโดเมนเฉพาะ

งานวิชาการมุ่งเป้าไปที่การจัดการภาษาโบราณที่ยากลำบาก (เช่น สันสกฤต บาลี ทิเบต) ให้สามารถนำมาประมวลผลด้วย Machine Translation ได้ โดยตระหนักถึงความท้าทายเฉพาะตัว

ตัวอย่าง PaLI-X และศักยภาพมัลติโมดอล

PaLI-X เป็นแบบจำลองวิชันและภาษา (Vision-Language model) ขนาดใหญ่ ซึ่งมีความสามารถในการแปลภาษาไทย แม้ว่าจะไม่ใช่ตัวแปลภาษาบาลีโดยตรง แต่ความสามารถในการประมวลผลข้อความจากรูปภาพ (เช่น เอกสารที่สแกนหรือใบลาน) ชี้ให้เห็นว่า LLM มัลติโมดอลในอนาคตสามารถประมวลผลแหล่งข้อมูลภาษาบาลีที่ยังไม่ได้แปลงเป็นดิจิทัลได้อย่างรวดเร็ว โดยหลีกเลี่ยงความท้าทายของเทคโนโลยี OCR (Optical Character Recognition) ในเอกสารโบราณ

ตารางที่ 2: การวิเคราะห์เปรียบเทียบความเหมาะสมของ LLM สำหรับการแปลภาษาไทย-บาลี

หมวดหมู่โมเดล	**ตัวอย่าง**	**ความเชี่ยวชาญภาษาไทย**	**ความเชี่ยวชาญภาษาบาลี (โดยประมาณ)**	**ข้อจำกัด/ข้อผูกมัดหลัก**
LLMs กรรมสิทธิ์ทั่วไป	GPT-4o, Gemini 2	สูง	ปานกลาง (อิงการอนุมาน)	ค่าโทเคนสูง; ข้อมูลการฝึกฝนไม่เปิดเผย; ไม่สามารถแยกสนธิได้อย่างน่าเชื่อถือ.
LLMs โอเพนซอร์สในภูมิภาค	Llama-3-Typhoon	สูง	ต่ำ (ต้องปรับตัวเฉพาะโดเมน)	ข้อมูลการฝึกฝนเน้นภาษาสมัยใหม่; ขาดชุดข้อมูลบาลีสำหรับการปรับจูนที่มีประสิทธิภาพ.
เครื่องมือเฉพาะทางสถาบัน	E-Tipitaka, PuriDict	N/A (การค้นหา/พจนานุกรม)	สูง (อิงคำศัพท์/วลี)	ขาดความสามารถในการแปลแบบลำดับต่อลำดับตามบริบท (Sequence-to-sequence machine translation) (ไม่ใช่ LLM).
NLP วิชาการเฉพาะทาง	Pali Morphological Analyzers	N/A	สูง (การวิเคราะห์ภาษาศาสตร์)	ให้บริการเฉพาะการประมวลผลล่วงหน้า/การวิเคราะห์เท่านั้น ไม่ใช่การแปล; โดยทั่วไปไม่ได้บูรณาการเข้ากับ LLMs.

VI. เครื่องมือเฉพาะทางและโครงสร้างพื้นฐานเชิงสถาบันที่มีอยู่

ก่อนหน้าการมาถึงของ LLM งานวิจัย NLP สำหรับภาษาบาลีได้มุ่งเน้นไปที่การสร้างเครื่องมือพื้นฐานเพื่อจัดการกับความซับซ้อนทางสัณฐานวิทยาของภาษา

6.1 การทบทวนงานวิจัย NLP พื้นฐานของภาษาบาลี

ความพยายามทางวิชาการได้มุ่งเน้นไปที่การพัฒนาเครื่องมือที่จำเป็นสำหรับการประมวลผลภาษาธรรมชาติภาษาบาลี เช่น ตัววิเคราะห์ (Analyzers) และตัวสร้าง (Generators) เครื่องมือเหล่านี้ดำเนินการงานที่ซับซ้อนอย่างอัตโนมัติ เช่น การระบุรากศัพท์ การ

วิเคราะห์การผันคำ และการแยกคำประสม (สมาส) งานวิจัยที่เฉพาะเจาะจงได้อธิบายถึงระบบที่ดำเนินการวิเคราะห์และสร้างคำภาษาบาลีโดยทำงานร่วมกับกระบวนทัศน์การผันคำปกติและฐานข้อมูลคำศัพท์

ความสำคัญของการบูรณาการกฎภาษา

การมีอยู่ของระบบที่อิงกฎเกณฑ์เหล่านี้ ยืนยันว่าภาษาบาลีต้องการมากกว่าการอนุมานทางสถิติที่บริสุทธิ์ของ LLM เท่านั้น แต่ต้องการการบูรณาการกฎทางภาษาศาสตร์ในเชิงลึก (เช่น กฎการทำสนธิของกัจจายนะ) เพื่อให้สามารถแยกคำในขั้นตอนการประมวลผลล่วงหน้าได้อย่างถูกต้อง นักวิจัยได้สร้างไวยากรณ์เชิงคำนวณสำหรับเครื่องมือสนธิในภาษาบาลีโดยอิงจากกฎของปาณินิ

6.2 โครงการมนุษยศาสตร์ดิจิทัลในประเทศไทย (ชั้นข้อมูล)

โครงการด้านมนุษยศาสตร์ดิจิทัลในประเทศไทยได้สร้างชั้นข้อมูลและเครื่องมืออ้างอิงที่มีคุณค่าอย่างยิ่ง ซึ่งเป็นองค์ประกอบพื้นฐานสำหรับการฝึกฝน LLM ในอนาคต

- **ฐานข้อมูลภาษาบาลี (PaliDB):** โครงการพัฒนาฐานข้อมูลคำภาษาบาลี เสนอคำศัพท์ภาษาบาลีที่ค้นหาได้พร้อมคำแปลภาษาไทย คำอ่าน และคำที่เกี่ยวข้อง ระบบนี้เป็นผลมาจากการวิจัยและพัฒนาโดยใช้ Methodology แบบ Spiral Model
- **พจนานุกรมและเอกสารดิจิทัล:** ทรัพยากรดิจิทัล เช่น พจนานุกรมไทย-บาลีของ MCU และปทานุกรม บาลี ไทย อังกฤษ สันสกฤต ฉบับประวัติศาสตร์ที่จัดเก็บในหอจดหมายเหตุดิจิทัล เป็นแหล่งข้อมูลศัพท์ที่มีคุณภาพสูงและเป็นแหล่งข้อมูลความจริงพื้นฐาน (Ground-Truth) สำหรับการฝึกฝนและการตรวจสอบความถูกต้องของ LLM
- **แอปพลิเคชันเฉพาะทาง:** แอปพลิเคชันเช่น E-Tipitaka และ PuriDict ซึ่งช่วยในการค้นหาพระไตรปิฎกภาษาไทย-บาลีและคำศัพท์ภาษาบาลี-ไทย ตามลำดับ แสดงให้เห็นถึงวิธีการที่มีอยู่ในการเข้าถึงความรู้ทางบาลี แม้ว่าเครื่องมือเหล่านี้จะไม่ได้เป็นระบบ Machine Translation ที่ใช้ LLM ก็ตาม

ความสัมพันธ์เชิงเหตุผล: พจนานุกรมสู่ท่อการแปล

ทรัพยากรคำศัพท์ (พจนานุกรม PaliDB) สร้างได้ง่ายกว่าชุดข้อมูลคู่ขนานในระดับประโยค ทรัพยากรคำศัพท์คุณภาพสูงเหล่านี้มีความสำคัญอย่างยิ่งต่อการฝึกฝนชั้นคำศัพท์ของ LLM (Embedding Layer) ซึ่งช่วยปรับปรุงความครอบคลุมของคำศัพท์และจัดการกับปัญหา OOV ได้ และยังสามารถใช้เป็นแหล่งข้อมูลอ้างอิงสำหรับการตรวจสอบความถูกต้องของการแปลที่สร้างโดย LLM

ตารางที่ 3: สรุปทรัพยากรดิจิทัลภาษาไทย/บาลีที่มีอยู่และศักยภาพของข้อมูล

ทรัพยากร/โครงการ	ลักษณะของเนื้อหา	การสนับสนุนต่อการฝึกฝน LLM	การเข้าถึง/สถานะ
พระไตรปิฎก ไทย/บาลี (MCU)	ข้อความคู่ขนานทางศาสนาขนาดใหญ่ (ฉบับละ 45 เล่ม).	**แหล่งข้อมูลปฐมภูมิ:** ให้ประโยคคู่ขนานที่จำเป็นสำหรับการปรับจูนอย่างละเอียด (Supervised fine-tuning).	ถูกจำกัด/แยกส่วน (มักอยู่ในรูปแบบทางกายภาพหรือดิจิทัลที่เป็นกรรมสิทธิ์ เช่น ซีดี-รอม).
PaliDB/PuriDict	รายการคำศัพท์, รายการพจนานุกรม, ข้อมูลสัณฐานวิทยา.	**การสนับสนุนคำศัพท์:** จำเป็นสำหรับการครอบคลุมคำศัพท์และการแก้ไขปัญหา OOV.	เข้าถึงได้สาธารณะ (ฐานข้อมูล, แอป, เว็บไซต์).
เครื่องมือไวยากรณ์เชิงคำนวณ	ตัวแยกสนธิ, ตัววิเคราะห์สัณฐานวิทยา.	**ชั้นประมวลผลล่วงหน้า:** สำคัญสำหรับการแยกคำที่ถูกต้องและการจัดการอินพุตภาษาบาลีที่ซับซ้อน.	ผันแปร (มักเป็นโค้ดวิจัยโอเพนซอร์สหรือเอกสารทางวิชาการ).
ชุดข้อมูลคู่ขนานอังกฤษ-ไทย	ข่าวสาร, ข้อความที่รวบรวมจากเว็บ (เช่น SCB-MT).	**ฐานการถ่ายโอนการเรียนรู้:** ให้ความสามารถทางภาษาไทยและการฝังตัวแบบข้ามภาษา.	เผยแพร่สู่สาธารณะ (มักเป็นโอเพนซอร์ส).

VII. การสังเคราะห์และการให้ข้อเสนอแนะเชิงกลยุทธ์

7.1 สถานะปัจจุบัน: ข้อพิสูจน์เชิงการดำรงอยู่เทียบกับความพร้อมในการผลิต

ข้อสรุปเกี่ยวกับการมีอยู่ของ LLM ที่แปลภาษาบาลีได้: ในขณะที่มีเครื่องมือและแพลตฟอร์มออนไลน์ที่อ้างว่าสามารถแปลภาษาไทยเป็นภาษาบาลีได้ (เช่น Rephrasely) แต่เครื่องมือเหล่านี้ส่วนใหญ่มักเป็นการแปลตามคำศัพท์หรือวลี หรือเป็นการแปลจากระบบ Machine Translation แบบดั้งเดิมที่ใช้สถิติ ไม่ใช่ระบบ LLM ที่แท้จริง และขาดความแม่นยำระดับใช้งานทางวิชาการสำหรับข้อความที่ซับซ้อน

ความสามารถในการแปลภาษาบาลีอาศัยการอนุมานในโมเดลทั่วไป (เช่น GPT-4) แต่ประสิทธิภาพของมันไม่เพียงพอสำหรับการใช้งานเชิงวิชาการเนื่องจากข้อจำกัดด้านภาษาศาสตร์และข้อมูล แนวโน้มของโครงการ LLM ที่สำคัญในประเทศไทย (เช่น Typhoon) ยังคงเน้นที่งาน NLP สำหรับภาษาไทยสมัยใหม่ในเชิงพาณิชย์และทั่วไป ทำให้ภาษาประวัติศาสตร์เฉพาะโดเมนยังไม่ได้รับการพัฒนาโมเดลเฉพาะทางอย่างเต็มที่

7.2 ข้อเสนอแนะเชิงกลยุทธ์สำหรับการพัฒนา LLM ภาษาไทย-บาลีที่มีความทนทาน

การเปลี่ยนผ่านจากการวิจัยเชิงทฤษฎีไปสู่ LLM ภาษาไทย-บาลีที่ใช้งานได้จริงต้องอาศัยกลยุทธ์ที่เน้นการบูรณาการระหว่างเทคโนโลยี LLM สมัยใหม่กับความรู้เฉพาะทางทางภาษาศาสตร์

ข้อเสนอแนะที่ 1: การเป็นพันธมิตรเชิงสถาบันและการจัดเรียงข้อมูล

สิ่งสำคัญที่สุดคือการแสวงหาความร่วมมือกับองค์กรต่างๆ เช่น มหาวิทยาลัยมหาจุฬาลงกรณราชวิทยาลัย เพื่อขออนุญาตใช้และจัดเรียงชุดข้อมูลพระไตรปิฎกคู่ขนานภาษาไทย-บาลีในเชิงคำนวณอย่างเป็นระบบ นี่คือเส้นทางเดียวที่จะเอาชนะอุปสรรคความขาดแคลนข้อมูลได้อย่างรวดเร็ว

ข้อเสนอแนะที่ 2: การพัฒนากลไกสถาปัตยกรรมลูกผสม (Hybrid Architecture)

LLM ในอนาคตจะต้องบูรณาการองค์ประกอบ NLP แบบดั้งเดิมที่อิงกฎเกณฑ์เข้าด้วยกัน: **ตัววิเคราะห์สัณฐานวิทยาภาษาบาลีและตัวแยกสนธิ** ซึ่งควรทำหน้าที่เป็นชั้นประมวลผลล่วงหน้าภาคบังคับก่อนที่จะป้อนข้อมูลเข้าสู่ตัวเข้ารหัส (Transformer encoder) การทำเช่นนี้จะรับประกันการระบุขอบเขตโทเคนที่ถูกต้อง ซึ่งเป็นรากฐานสำหรับความเข้าใจทางไวยากรณ์ในระดับที่ซับซ้อน (ตามหลักการที่กำหนดโดยงานวิจัยใน)

ข้อเสนอแนะที่ 3: การใช้ประโยชน์จากการถ่ายโอนการเรียนรู้

ควรใช้แบบจำลองในภูมิภาคที่มีความเชี่ยวชาญด้านภาษาไทยสูง (เช่น Llama-3-Typhoon) เป็นฐานเริ่มต้น เนื่องจากมีทักษะความเข้าใจภาษาเป้าหมาย (ภาษาไทย) อยู่แล้ว จากนั้นจึงดำเนินการปรับจูนอย่างละเอียด (Fine-tuning) โดยใช้ชุดข้อมูลคู่ขนานภาษาบาลี-ไทยที่จัดเรียงใหม่ ซึ่งจะช่วยให้โมเดลสามารถถ่ายโอนความรู้ทั่วไปมาใช้ในการแปลโดเมนเฉพาะได้

7.3 แนวโน้มในอนาคต: บทบาทของ AI มัลติโมดอล

ดังที่แสดงให้เห็นโดยแนวคิดของแบบจำลอง PaLI-X การบูรณาการความสามารถของ Vision-Language (V&L) จะมีความสำคัญอย่างยิ่งในอนาคต ความสามารถนี้ช่วยให้ LLM สามารถอ่านและตีความเอกสารภาษาบาลีทางประวัติศาสตร์โดยตรง (เช่น รูปภาพของใบลานหรือต้นฉบับลายมือ) ซึ่งมักมีปัญหาความไม่น่าเชื่อถือของ OCR สิ่งนี้จะช่วยลดช่องว่างระหว่างการเก็บถาวรดิจิทัลกับการแปลเชิงคำนวณได้อย่างมีนัยสำคัญ.