รายงานผู้เชี่ยวชาญ: กลยุทธ์การ Fine-Tune LLM สำหรับการวางแผนการท่องเที่ยวที่มีประสิทธิภาพในประเทศไทย (LLM Agent Strategy for Feasible and Personalized Trip Planning in Thailand)

ส่วนที่ 1: การวิเคราะห์ความท้าทายและทางออกด้วยระบบลูกผสม (Analysis of Planning Challenges and Hybrid Solutions)

1.1 ความท้าทายโดยธรรมชาติของ LLM ในงานวางแผนเชิงลอจิสติกส์

Large Language Models (LLMs) ที่ผ่านการฝึกฝนทั่วไป (General-purpose LLMs) แสดงความสามารถที่ยอดเยี่ยมในการสร้างภาษาธรรมชาติที่ลื่นไหลและการให้เหตุผลเชิงสามัญสำนึก (Commonsense Reasoning) แต่กลับประสบปัญหาอย่างมีนัยสำคัญเมื่อต้องเผชิญกับปัญหาการวางแผนที่มีข้อจำกัดเชิงปริมาณหลายมิติ (Complex Multi-Constraint Planning) การวางแผนการเดินทางไม่ใช่แค่การเล่าเรื่อง แต่เป็นปัญหาการจัดเรียงเชิงลอจิสติกส์ที่ซับซ้อน หรือที่เรียกว่าปัญหา Combinatorial Optimization.

งานวิจัยล่าสุดพบว่า LLMs ที่ล้ำสมัย (state-of-the-art LLMs) มีความแม่นยำต่ำอย่างน่าตกใจในการสร้างแผนการเดินทางที่สามารถปฏิบัติได้จริง (viable solutions) โดยให้ผลลัพธ์ที่เป็นไปได้เพียง 4% หรือน้อยกว่านั้นของเวลาทั้งหมด แม้จะมีการเพิ่มความสามารถในการเรียกใช้เครื่องมือภายนอก (APIs) เข้ามาช่วยแล้วก็ตาม. ความเปราะบางนี้เกิดจากหลายปัจจัย:

ประการแรก คือการขาด **Grounding** หรือการอ้างอิงข้อมูลโลกจริงที่ทันสมัย. LLMs มักขาดข้อมูลล่าสุด เช่น เวลาเปิดทำการที่อัปเดต, ตารางการเดินทางแบบเรียลไทม์ หรือการปิดกิจการถาวรของสถานที่. การขาดข้อมูลที่ทันสมัยนี้ทำให้แผนการเดินทางที่ LLM สร้างขึ้นอาจมีองค์ประกอบที่ไม่สามารถปฏิบัติได้จริง (Impractical Elements) เช่น การแนะนำให้ไปเยี่ยมชมพิพิธภัณฑ์ที่ปิดทำการไปแล้ว หรือการกำหนดเส้นทางที่ต้องใช้การเดินทางข้ามเมืองเป็นระยะทางไกลโดยไม่จำเป็นภายในวันเดียว. ประการที่สองคือ **อคติในการสร้างผลลัพธ์ที่ยาว** (Length Bias) นักวิจัยได้สังเกตว่า LLM planners มักจะสร้างแผนที่ยาวเกินความจำเป็น ซึ่งอาจนำไปสู่เส้นทางที่ไม่เหมาะสมที่สุด (non-optimality in path planning) ซึ่งแตกต่างจากความต้องการของผู้ใช้งานที่ต้องการแผนที่มีประสิทธิภาพและตรงไปตรงมา.

1.2 แนวคิดของ LLM Agent และสถาปัตยกรรมระบบลูกผสมสำหรับการวางแผนการท่องเที่ยว

เนื่องจาก LLMs มีความแข็งแกร่งในการจัดการกับความต้องการที่ "นุ่มนวล" (Soft Requirements) เช่น รสนิยม ความชอบส่วนบุคคล และการตีความความต้องการของผู้ใช้ในภาษาธรรมชาติ แต่ล้มเหลวในการจัดการกับข้อจำกัดที่ "ยาก" (Hard Constraints) ที่เกี่ยวข้องกับลอจิสติกส์และเวลา. ดังนั้น กลยุทธ์การพัฒนาจึงต้องเปลี่ยนจากการพยายามสร้าง LLM ที่ทำทุกอย่างได้ มาเป็นการสร้าง **Hybrid Agentic System**

สถาปัตยกรรมระบบลูกผสมจะใช้ LLM เป็นเพียงส่วนประกอบการให้เหตุผลเชิงภาษา (Reasoning Engine) ในการเริ่มต้นเท่านั้น โดยมีการบูรณาการกับเครื่องมือภายนอกเพื่อตรวจสอบความถูกต้องเชิงลอจิสติกส์.

ขั้นตอนการทำงานของ Hybrid Agent Architecture

1. **Phase 1: LLM Initiation and Interpretation:** LLM (เช่น รุ่น Gemini) จะรับคำสั่งของผู้ใช้และตีความเจตนา (Intent) ก่อนสร้างโครงร่างแผนเริ่มต้น (Initial Plan Suggestion) ซึ่งรวมถึงรายการกิจกรรมที่แนะนำ ระยะเวลาที่ควรใช้ และระดับความสำคัญของกิจกรรมนั้น ๆ.

2. **Phase 2: Grounding and Retrieval:** ระบบ Agent จะเรียกใช้ Search Backends หรือ API ภายนอก (Tool Calling) เพื่อนำข้อมูลโลกจริงที่ทันสมัยมาตรวจสอบความถูกต้องของแผนเริ่มต้น ข้อมูลที่ใช้ในการ Grounding รวมถึงเวลาเปิดทำการล่าสุดและเวลาเดินทางที่แน่นอน. ในขณะเดียวกัน Search Backends ก็จะค้นหากิจกรรมทางเลือกที่เกี่ยวข้องเพื่อใช้เป็นตัวเลือกสำรองหากแผนเดิมไม่สามารถทำได้จริง

3. **Phase 3: Optimization and Constraint Solving:** ข้อมูลที่ผ่านการ Grounding จะถูกส่งไปยัง Optimization Algorithm หรือ Satisfiability Solver. ขั้นตอนนี้เป็นหัวใจสำคัญ เพราะ Algorithm จะทำหน้าที่คำนวณหาแผนการเดินทางสุดท้ายที่ *เป็นไปได้* (Feasible) และมีเส้นทางที่เหมาะสมที่สุด (Optimized Route) ในขณะที่ยังคงความคล้ายคลึงกับความต้องการเริ่มต้นของผู้ใช้ที่ LLM ตีความไว้.

การประยุกต์ใช้สถาปัตยกรรมนี้ในประเทศไทยจึงต้องอาศัยการเชื่อมต่อที่แน่นหนา (Tight Integration) กับ API ที่ให้ข้อมูลสถานที่ (POI) และกิจกรรมของไทยที่ถูกต้องและเป็นปัจจุบัน เพื่อแก้ไขปัญหาความไม่สามารถปฏิบัติได้จริง (Impracticality) ที่ LLM ทั่วไปสร้างขึ้นมา.

1.3 การสำรวจโมเดลสำเร็จรูปและการประเมินความพร้อมใช้งานในประเทศไทย (Goal 1)

คำถามสำคัญคือมีโมเดลสำเร็จรูปสำหรับการวางแผนการท่องเที่ยวที่สามารถใช้ในประเทศไทยได้หรือไม่ การตรวจสอบพบว่ามีโมเดลและเครื่องมือที่กำลังพัฒนาทั้งในระดับสากลและระดับท้องถิ่น:

A. โมเดลเชิงวิจัยสากล: โมเดลเหล่านี้มักเป็นรากฐานสำหรับ Agent Architecture โดยเน้นไปที่ความสามารถในการให้เหตุผลและการจัดการข้อจำกัด เช่น TravelPlanner , TripTailor (มีข้อมูล POI กว่า 500,000 แห่ง) , และ TripCraft. อย่างไรก็ตาม โมเดลเหล่านี้ขาดการฝึกฝนบนชุดข้อมูลเชิงลึกเฉพาะของประเทศไทย ทำให้ต้องมีการ Fine-tune เพิ่มเติมเพื่อรับมือกับบริบทท้องถิ่นและภาษาไทย

B. โมเดลเฉพาะทางสำหรับบริบทไทย (MAHASAMUT และ PhuKhao LLM): มีการวิจัยที่เกี่ยวข้องกับ **MAHASAMUT Agent** ซึ่งใช้ **PhuKhao LLM** ในการวางแผนการเดินทางในประเทศไทย. ระบบนี้ได้รับการสาธิตความสามารถในการใช้ Search Agent เพื่อให้ข้อมูลที่ทันสมัยและมีการอ้างอิงแหล่งที่มา รวมถึงการสร้างรายละเอียดแผนการเดินทางและการแนะนำร้านอาหารท้องถิ่น.

ข้อจำกัดด้านลิขสิทธิ์และการใช้งานเชิงพาณิชย์ในไทย

ถึงแม้ PhuKhao LLM จะแสดงศักยภาพในการใช้งานในประเทศไทย แต่การประเมินความพร้อมในการใช้งานเชิงพาณิชย์ (Goal 1) ต้องพิจารณาถึงสถานะลิขสิทธิ์. ข้อมูลที่มีอยู่ในปัจจุบันไม่ได้ระบุสถานะลิขสิทธิ์ของ PhuKhao LLM อย่างชัดเจน. การนำโมเดลที่เป็น Open Source แต่มีข้อจำกัดด้านการใช้งานเชิงพาณิชย์ (เช่น Non-commercial license) หรืออยู่ภายใต้เงื่อนไข Copyleft ที่เข้มงวดมาพัฒนาผลิตภัณฑ์เชิงพาณิชย์ ถือเป็นความเสี่ยงทางกฎหมายที่สูง.

ดังนั้น สำหรับการพัฒนาผลิตภัณฑ์ในระยะยาวที่ต้องการความมั่นคงทางกฎหมาย กลยุทธ์ที่ปลอดภัยกว่าคือการเลือกใช้ **Base Model สากล (เช่น Llama, Mistral) ที่มีลิขสิทธิ์แบบ Permissive** (เช่น Apache 2.0) และใช้กระบวนการ Fine-tune ที่เข้มข้นเพื่อเพิ่มความสามารถเฉพาะทางและภาษาไทยเข้าไป. การพึ่งพาโมเดลพื้นฐานที่มีลิขสิทธิ์ชัดเจนจะช่วยให้มั่นใจได้ว่าผลิตภัณฑ์เชิงพาณิชย์ที่พัฒนาขึ้นมาจะไม่เผชิญกับข้อพิพาททางทรัพย์สินทางปัญญาในอนาคต.

ส่วนที่ 2: กลยุทธ์ข้อมูลสำหรับการปรับให้เข้ากับบริบทไทย (Data Strategy for Thai Localization and Fine-Tuning) (Goal 2)

2.1 ความจำเป็นของการ Fine-Tuning ด้วยข้อมูลเฉพาะทาง (Supervised Fine-Tuning - SFT)

LLMs ที่ได้รับการฝึกฝนทั่วไปขาดความรู้เฉพาะด้านการท่องเที่ยว (Tourism Knowledge) ที่ละเอียดอ่อนและถูกต้องในระดับท้องถิ่น. การปรับแต่งโมเดล (Fine-tuning) จึงเป็นขั้นตอนที่จำเป็นเพื่อให้ LLM Agent สามารถสร้างแผนที่สอดคล้องกับพฤติกรรม วัฒนธรรม ภาษา และข้อมูลทางภูมิศาสตร์ของประเทศไทยอย่างแท้จริง การ Fine-tuning ในบริบทนี้ควรเน้นที่ Supervised Fine-Tuning (SFT) เพื่อถ่ายทอดความรู้เชิงลอจิสติกส์และการให้เหตุผลตามคำสั่งที่ซับซ้อน.

2.2 ประเภทข้อมูลที่จำเป็นสำหรับการ Instruction Tuning และการจัดหา (Goal 2)

การสร้าง LLM Planner ที่มีประสิทธิภาพต้องอาศัยชุดข้อมูลที่มีคุณภาพสูง 3 ประเภทหลัก ซึ่งทั้งหมดจะต้องถูกแปลงให้เป็นภาษาไทยที่ถูกต้อง:

A. Conversational & QA/Instruction Data

ชุดข้อมูลนี้มีวัตถุประสงค์เพื่อฝึกให้โมเดลเข้าใจเจตนาของผู้ใช้ (User Intent) การจัดการบทสนทนาแบบไดนามิก (Conversational AI) และการสร้างคำตอบตามคำสั่งที่ชัดเจน.

- **ลักษณะข้อมูล**: ประกอบด้วยคู่คำสั่ง (Instruction/User Request), บริบท (Input/Constraints), และผลลัพธ์ที่ต้องการ (Response/Itinerary).
- **กลยุทธ์การจัดหา**: สามารถเริ่มต้นจากการใช้ชุดข้อมูล QA เชิงการเดินทางระดับสากลที่มีขนาดใหญ่ (เช่น Bitext Travel QA Pairs ซึ่งมีโทเคนรวม 4.16 ล้านโทเคน) และดำเนินการแปล การปรับเปลี่ยนคำศัพท์ และการปรับบริบท (Adaptation) ให้สะท้อนถึงสำนวนภาษาไทยและสถานการณ์การเดินทางในประเทศ

B. Point of Interest (POI) และ Tourism Knowledge Base Data

ข้อมูลนี้ทำหน้าที่เป็นรากฐานความรู้ (Grounding Knowledge) ให้กับ LLM เกี่ยวกับสถานที่จริง กิจกรรม และข้อมูลปฏิบัติการที่สำคัญต่อการวางแผน.

- **ลักษณะข้อมูล**: ชื่อสถานที่, พิกัด, ประเภทสถานที่ (ร้านอาหาร, ที่เที่ยว), เวลาเปิด-ปิด, ราคาโดยประมาณ, และข้อมูลเชิงวัฒนธรรม (เช่น ข้อมูลกิจกรรมทั่วไทยแยกตามเทศกาล).
- **กลยุทธ์การจัดหาแหล่งข้อมูลไทย**:
    1. **TAT Data API:** แหล่งข้อมูลหลักจากรัฐบาลไทย (การท่องเที่ยวแห่งประเทศไทย) ซึ่งมี API Endpoints ที่ชัดเจนสำหรับ Places (สถานที่), Events (กิจกรรม), Routes (เส้นทางแนะนำ), และ Provinces (จังหวัด). การเข้าถึงข้อมูลกิจกรรมทั่วไทยที่จัดตามเทศกาลถือเป็นประโยชน์อย่างยิ่ง.
    2. **Open Data ทางภูมิศาสตร์**: การใช้ข้อมูล Points of Interest (POI) ทางภูมิศาสตร์จาก OpenStreetMap ในประเทศไทย (hotosm_tha_points_of_interest) ซึ่งมีการอัปเดตเป็นประจำทุกเดือน.
    3. **ข้อมูลเชิงพาณิชย์**: รวบรวมข้อมูลรีวิว ความนิยม และความทันสมัยจากแพลตฟอร์มเชิงพาณิชย์ (เช่น TripAdvisor, Booking.com, Agoda) ผ่านการทำ Web Scraping เพื่อเสริมข้อมูล POI ในพื้นที่ท่องเที่ยวหลัก เช่น กรุงเทพฯ, เชียงใหม่, ภูเก็ต, พัทยา, และหาดใหญ่.

C. Structured Itineraries with Constraints (Hard Constraint Data)

นี่คือชุดข้อมูลที่สำคัญที่สุดสำหรับการฝึกฝนความสามารถในการวางแผนเชิงลอจิสติกส์ ชุดข้อมูลนี้จะสอนให้ LLM เรียนรู้การจัดลำดับ POI การคำนวณระยะเวลาเยี่ยมชมที่เหมาะสม (Appropriate Visit Duration) การวางแผนเส้นทางที่เหมาะสมที่สุด (Optimized Route) และการจัดการงบประมาณ (Defined Budget Limit).

- **ลักษณะข้อมูล**: แผนการเดินทางแบบ Day-by-Day ที่มีโครงสร้างชัดเจน พร้อมพิกัด เวลาเข้า-ออก งบประมาณ และระบุว่าข้อจำกัดทั้งหมดได้รับการตอบสนอง.
- **กลยุทธ์การจัดหา**: ใช้ข้อมูลเส้นทางแนะนำจาก TAT API และชุดข้อมูลสถิติการท่องเที่ยวในประเทศ (เช่น ข้อมูลสถิติรายเดือนใน 77 จังหวัด ปี 2019-2023) และแปลงข้อมูลสถิติเชิงปริมาณเหล่านี้ให้เป็น **Instruction Format** โดยการสร้างสถานการณ์สมมติที่มีเงื่อนไขเชิงลอจิสติกส์ที่ต้องแก้ไข.

2.3 ข้อพิจารณาด้านลิขสิทธิ์สำหรับการใช้ข้อมูลรัฐบาลไทยเชิงพาณิชย์

การใช้ประโยชน์จากแหล่งข้อมูลขนาดใหญ่ของรัฐบาลไทย (TAT Data API, data.go.th) ต้องมีการตรวจสอบอย่างรอบคอบเกี่ยวกับเงื่อนไขทางกฎหมาย. โดยทั่วไป Open Data ถูกกำหนดให้สามารถใช้ซ้ำและเผยแพร่ต่อได้โดยมีข้อจำกัดน้อยที่สุด (เช่น CC-By หรือ CC0). อย่างไรก็ตาม ข้อมูลรัฐบาลไทยเคยใช้ EGA Open Government Licence. ทีมพัฒนาจำเป็นต้องยืนยันอย่างชัดเจนว่าเงื่อนไขปัจจุบันของ TAT Data API อนุญาตให้ใช้ข้อมูลเหล่านี้ในการ **Fine-tune โมเดล LLM สำหรับผลิตภัณฑ์เชิงพาณิชย์** หรือไม่

ความเสี่ยงด้านลิขสิทธิ์นี้มีความสำคัญอย่างยิ่ง เนื่องจากหากมีการจำกัดการใช้ข้อมูลเพื่อการฝึกฝนโมเดลเชิงพาณิชย์ การใช้ข้อมูลโดยตรงเป็น Training Data อาจนำไปสู่ข้อพิพาททางกฎหมายได้. ดังนั้น หากมีข้อจำกัดที่คลุมเครือหรือไม่เอื้ออำนวย ทีมควรใช้ข้อมูลจาก TAT Data API สำหรับการ **Grounding แบบเรียลไทม์** ผ่าน API Call ภายนอกเท่านั้น (ซึ่งเป็นส่วนหนึ่งของ Agent Architecture) และใช้เฉพาะชุดข้อมูลที่ได้รับอนุญาตอย่างชัดเจนเท่านั้นสำหรับการ Fine-tune.

ส่วนที่ 3: สถาปัตยกรรมข้อมูลและการเตรียมชุดข้อมูล (Data Architecture and Dataset Preparation)

3.1 รูปแบบข้อมูลสำหรับการ Instruction Tuning (Instruction Tuning Format)

เพื่อให้ LLM สามารถเรียนรู้การวางแผนที่มีโครงสร้างและข้อจำกัดที่ซับซ้อน ชุดข้อมูล SFT จะต้องถูกจัดโครงสร้างในรูปแบบ **Input-Instruction-Output** ซึ่งเป็นมาตรฐานสำหรับการ Instruction Tuning. รูปแบบไฟล์ที่แนะนำคือ JSONL เนื่องจากสามารถรองรับการจัดเก็บ Itinerary Output ที่มีความซับซ้อนหลายวันหรือมีการจัดโครงสร้างแบบซ้อน (Nested Structure) ได้ดีกว่า.

โครงสร้างหลักของชุดข้อมูล Instruction Tuning:

องค์ประกอบ	คำอธิบายและวัตถุประสงค์
Instruction	คำสั่งเฉพาะของผู้ใช้ เช่น "วางแผนเที่ยว 3 วันในเชียงใหม่สำหรับครอบครัวที่มีงบจำกัด"
Input (Context)	ข้อมูลบริบทและข้อจำกัดที่ LLM ต้องนำมาพิจารณาในการวางแผน เช่น วันที่เดินทาง, งบประมาณที่แน่นอน (15,000 บาท), รายการ POI ที่ถูกกรองแล้ว (พร้อมพิกัดและเวลาเปิด-ปิด).
Output (Completion)	แผนการเดินทางที่ถูกสร้างขึ้นและ **ผ่านการตรวจสอบความถูกต้องเชิงลอจิสติกส์แล้ว** (Ground-truth Itinerary) แผนนี้ควรอยู่ในรูปแบบที่มีโครงสร้างที่สามารถแยกวิเคราะห์ได้ (Parseable Format) เช่น Markdown Table หรือ JSON Schema. การใช้รูปแบบที่มีโครงสร้างช่วยให้สามารถประเมินผลอัตโนมัติได้ง่าย.

การออกแบบ Output ที่มีโครงสร้างนี้มีความสำคัญเชิงกลยุทธ์. หากโมเดลถูกฝึกให้สร้างผลลัพธ์ในรูปแบบ JSON ที่ระบุ POI, เวลาเดินทาง, และค่าใช้จ่ายอย่างชัดเจน ระบบตรวจสอบความถูกต้อง (Rule-based Feasibility Checker) และ Optimization Algorithm จะสามารถนำข้อมูลไปใช้ได้ทันที. สิ่งนี้ช่วยลดความจำเป็นในการพึ่งพาการประเมินจากมนุษย์ (Human Evaluation) ที่ช้าและมีค่าใช้จ่ายสูง

3.2 การปรับปรุงคุณภาพข้อมูล (Data Quality Assurance)

การรับประกันคุณภาพของข้อมูลที่ใช้ในการ Fine-tune เป็นสิ่งสำคัญในการป้องกันไม่ให้โมเดลเกิด "Catastrophic Forgetting" หรือถูกฝึกด้วย "แผนที่ไม่ดี" (Bad Plans).

1. **Feasibility and Rationality Checking:** ชุดข้อมูล SFT ทั้งหมดต้องได้รับการตรวจสอบล่วงหน้าว่าแผนการเดินทางที่เสนอมีความเป็นไปได้จริง (Feasible) และมีเหตุผล (Rational) โดยเฉพาะอย่างยิ่งการตรวจสอบว่าระยะเวลาเยี่ยมชมที่กำหนดเหมาะสม (Appropriate Visit Duration) และเส้นทางมีการจัดลำดับที่ถูกต้องตามหลักภูมิศาสตร์เพื่อลดเวลาเดินทาง.

2. **Geographical Validation:** ตรวจสอบความถูกต้องของพิกัด POI และความสอดคล้องของเส้นทางที่แนะนำกับความเป็นจริงทางภูมิศาสตร์ของประเทศไทย.

3. **Multilingual and Cultural Consistency:** จัดการกับการผสมผสานระหว่างภาษาไทยและภาษาอังกฤษในชุดข้อมูล (เช่น ชื่อจังหวัด, ชื่อ POI) และตรวจสอบให้แน่ใจว่าการตอบสนองมีความสอดคล้องกับบริบททางวัฒนธรรมไทย

ส่วนที่ 4: รายละเอียดขั้นตอนทางเทคนิคของการ Fine-Tuning (Detailed Technical Fine-Tuning Methodology) (Goal 3)

4.1 การเลือกเทคนิค Parameter-Efficient Fine-Tuning (PEFT)

เนื่องจาก LLMs ที่มีศักยภาพสูงมักมีขนาดหลายพันล้านพารามิเตอร์ (Billion parameters) การ Fine-tuning แบบเต็มรูปแบบ (Full Fine-tuning) จึงต้องใช้ทรัพยากรคอมพิวเตอร์และหน่วยความจำมหาศาล. เทคนิค **Parameter-Efficient Fine-Tuning (PEFT)** จึงเป็นทางออกเชิงกลยุทธ์ที่จำเป็นสำหรับการพัฒนา LLM Planner ในเชิงพาณิชย์.

PEFT ช่วยลดความต้องการด้านคอมพิวเตอร์และเวลาฝึกฝน โดยการปรับปรุงเฉพาะพารามิเตอร์ที่สำคัญและเกี่ยวข้องที่สุดในโครงข่ายประสาทเทียมเท่านั้น. เทคนิคหลักที่แนะนำคือ **LoRA (Low-Rank Adaptation)** และ **QLoRA (Quantized LoRA)**.

- **LoRA:** ลดจำนวนพารามิเตอร์ที่ต้องฝึกฝน โดยการเพิ่มเมทริกซ์ปรับขนาดเล็ก (low-rank matrices) เข้าไปในเลเยอร์ Attention ของโมเดล.
- **QLoRA:** ใช้เทคนิค Quantization (เช่น 4-bit) เพื่อลดความแม่นยำของพารามิเตอร์ของ Base Model ซึ่งช่วยลดการใช้หน่วยความจำเพิ่มเติมได้อย่างมากในขณะที่ยังคงประสิทธิภาพไว้.

4.2 ขั้นตอนทางเทคนิคของการ Fine-tuning ด้วย PEFT (LoRA Implementation) (Goal 3)

การ Fine-tune LLM Planner ด้วยเทคนิค SFT/PEFT มีขั้นตอนดังต่อไปนี้:

1. **Step 1: การตั้งค่าสภาพแวดล้อม**: ติดตั้งไลบรารีที่จำเป็น เช่น Hugging Face Transformers, PEFT, Accelerate, และ bitsandbytes (หากใช้ QLoRA).
2. **Step 2: การโหลด Pre-Trained Model และ Tokenizer:** เลือก Base Model ที่มีความสามารถด้านภาษาไทยที่ดีและมีลิขสิทธิ์แบบ Permissive (เช่น Llama 3 หรือ Mistral ที่มี Apache 2.0 License). โมเดลควรถูกโหลดด้วยการควอนไทซ์ 4-bit (กรณีใช้ QLoRA) เพื่อประหยัดหน่วยความจำ.
3. **Step 3: การเตรียมชุดข้อมูล**: แปลงชุดข้อมูลทั้งหมด (Conversational QA, POI KB, Structured Itineraries) ให้อยู่ในรูปแบบ Instruction Tuning (JSONL) ที่เหมาะสม และแบ่งข้อมูลเป็น Training Set และ Validation Set อย่างระมัดระวัง.
4. **Step 4: การกำหนดค่า LoRA Adapter (PeftConfig):** กำหนด Hyperparameters ที่สำคัญเพื่อควบคุมการเรียนรู้:

- **r (LoRA Rank):** กำหนดมิติของเมทริกซ์ปรับปรุง (เช่น 8, 16, 32).
- **lora_alpha (Scaling Factor):** ตัวประกอบการปรับขนาด, มักกำหนดเป็นค่าที่สอดคล้องกับ r.
- **target_modules:** ระบุเลเยอร์ของโมเดลที่จะทำการ Fine-tune ซึ่งโดยทั่วไปจะมุ่งเป้าไปที่เมทริกซ์ Query, Key, และ Value ใน Attention Layer เพื่อให้การปรับตัวมีประสิทธิภาพสูงสุด.

5. **Step 5: การกำหนดค่า Training Arguments และเริ่มต้นการฝึก**: กำหนด Learning Rate ที่เหมาะสม การกำหนด Learning Rate ที่ต่ำเกินไปจะนำไปสู่ Underfitting ในขณะที่การกำหนดจำนวน Epochs ที่สูงเกินไปหรือ Learning Rate ที่ไม่เหมาะสมอาจนำไปสู่ Overfitting หรือที่ร้ายแรงกว่านั้นคือ Catastrophic Forgetting ซึ่งทำให้โมเดลลืมความรู้ที่เรียนรู้มาตั้งแต่ต้น.
6. **Step 6: การตรวจสอบ (Monitoring) และการป้องกัน Overfitting:** ใช้เครื่องมือตรวจสอบ เช่น WandB (Weights and Biases) เพื่อติดตามผลลัพธ์ โดยเฉพาะอย่างยิ่งความแตกต่างระหว่าง Training Loss และ Validation Loss. หาก Validation Loss เริ่มเพิ่มขึ้นอย่างมีนัยสำคัญในขณะที่ Training Loss ยังคงลดลง แสดงว่าเกิด Overfitting และต้องหยุดการฝึกทันที.

4.3 การผสานรวม LLM กับ Solver/Grounding Layer (Agent Protocol)

กระบวนการ Fine-tuning ต้องรวมถึงการสอนให้ LLM สามารถสร้างผลลัพธ์ที่เป็นโครงสร้างที่ใช้งานได้ภายนอก (Tool Calling) เพื่อเชื่อมต่อกับ Agent Architecture.

การออกแบบ Prompt และชุดข้อมูล SFT ต้องฝึกให้ LLM สร้างผลลัพธ์ที่มีรูปแบบเฉพาะ (เช่น JSON) ที่ระบุฟังก์ชันการทำงานที่ต้องการเรียกใช้และพารามิเตอร์ที่เกี่ยวข้อง ตัวอย่างเช่น การขอข้อมูลเวลาเปิดทำการจาก TAT Data API: call_tool(name='TAT_API_Place_Details', params={'place_id': 'Phuket_Beach_1', 'date': '2025-01-01'}). การเรียก API เหล่านี้จะทำหน้าที่เป็นชั้น Grounding เพื่อให้มั่นใจว่าข้อมูลเวลาเปิด-ปิดและเวลาเดินทางที่แน่นอนถูกนำมาพิจารณาก่อนที่ Optimization Algorithm จะสร้างแผนการเดินทางสุดท้ายที่ปฏิบัติได้จริง.

ส่วนที่ 5: การประเมินผลและการวัดประสิทธิภาพ (Evaluation and Performance Metrics)

5.1 ความสำคัญของการประเมินเฉพาะทางสำหรับ LLM Planner

การประเมินประสิทธิภาพของ LLM Planner ไม่สามารถพึ่งพาเมตริก NLP แบบดั้งเดิม (เช่น BLEU หรือ ROUGE) ซึ่งเน้นที่ความคล้ายคลึงของโทเคนเท่านั้นได้. แผนการเดินทางที่ถูกสร้างขึ้นอาจมีรูปแบบภาษาที่แตกต่างกัน แต่ยังคงมีประสิทธิภาพสูงหรือต่ำกว่าแผนอ้างอิง. การประเมินจึงต้องมุ่งเน้นไปที่คุณภาพเชิงโครงสร้างและความถูกต้องเชิงลอจิสติกส์

ของแผนที่สร้างขึ้น (Plan Quality). กรอบการประเมินควรครอบคลุมสามมิติหลัก ได้แก่ ความเป็นไปได้ (Feasibility), ความครอบคลุม (Completeness), และการปรับให้เป็นส่วนตัว (Personalization).

5.2 กรอบการประเมินผลสำหรับ LLM Trip Planning Agent

A. Feasibility และ Rationality (ความเป็นไปได้เชิงลอจิสติกส์)

เมตริกเหล่านี้วัดความถูกต้องตามกฎเกณฑ์ที่เข้มงวด (Hard Constraints) และสามารถตรวจสอบได้โดยอัตโนมัติ (Rule-based Metrics).

- **Optimized Route:** วัดว่าแผนที่เสนอนั้นลดเวลาการเดินทางระหว่าง Points of Interest (POI) ได้อย่างมีประสิทธิภาพหรือไม่.
- **Non-conflicting Constraints:** ตรวจสอบความขัดแย้งเชิงลอจิสติกส์ เช่น การจัดกิจกรรมในช่วงเวลาที่สถานที่เปิดทำการ , หรือการขัดแย้งกันของวิธีการขนส่งภายในทริป (เช่น ไม่ควรมีการแนะนำ "การขับรถเอง" ควบคู่ไปกับการ "บิน" ในการเดินทางระหว่างเมือง หากไม่ได้รับการระบุอย่างชัดเจน).
- **Appropriate Visit Duration:** ตรวจสอบว่าระยะเวลาที่กำหนดให้แต่ละ POI อยู่ในช่วงเวลาที่สมเหตุสมผลและสอดคล้องกับประเภทของสถานที่นั้น ๆ.

B. Completeness และ Comprehensiveness (ความสมบูรณ์และครอบคลุม)

เมตริกเหล่านี้ตรวจสอบว่า LLM ตอบสนองต่อคำสั่งของผู้ใช้อย่างครบถ้วนหรือไม่

- **Comprehensiveness (CPH) และ Completeness (CPL):** ตรวจสอบว่าทุกองค์ประกอบที่ผู้ใช้ร้องขอในคำสั่งได้รับการตอบสนองในแผนการเดินทางหรือไม่.
- **Defined Budget Limit:** ตรวจสอบโดยอัตโนมัติว่าค่าใช้จ่ายรวมโดยประมาณของแผนที่เสนอไม่เกินงบประมาณที่ผู้ใช้กำหนดไว้ในคำสั่ง.

C. Personalization (PER) (การปรับให้เป็นส่วนตัว)

การประเมินมิติของการปรับให้เป็นส่วนตัวเป็นเรื่องเชิงคุณภาพที่ยากต่อการวัดด้วยสคริปต์อัตโนมัติ.

- **Individual Preference:** ประเมินว่าแผนการเดินทางมีการผสานองค์ประกอบเฉพาะบุคคล (เช่น ความสนใจ, ประเภทอาหารที่ชอบ, ความเข้มข้นของกิจกรรม) เข้ากับแผนอย่างลึกซึ้งหรือไม่.

- **Human/LLM-assisted Evaluation:** การประเมินด้านนี้มักต้องอาศัยการประเมินจากมนุษย์ (Aggregated Assessment from Travelers) หรือใช้ LLM ระดับสูงมาทำหน้าที่เป็น Evaluator เพื่อให้คะแนน โดยใช้เกณฑ์เฉพาะทาง เช่น CRA (Consistency, Readability, Availability) เพื่อรับรองคุณภาพของแผนการเดินทางที่สร้างขึ้น.

D. RAG และ Tool Calling Metrics

หาก LLM Agent ใช้ Retrieval Augmented Generation (RAG) หรือ Tool Calling เพื่อดึงข้อมูล POI หรือข้อมูลจริงจาก TAT Data API เพื่อการ Grounding , ประสิทธิภาพของการค้นหาจะต้องถูกวัดผลด้วย:

- **MRR (Mean Reciprocal Rank), Precision @ K, และ NDCG (Normalized Discounted Cumulative Gain):** เมตริกเหล่านี้ช่วยในการกำหนดว่าระบบ Search Backend สามารถดึงข้อมูลที่เกี่ยวข้องและถูกต้องจากฐานความรู้ (Knowledge Base) กลับไปยัง Context Window ของ LLM ได้ดีเพียงใด.

ตารางที่ 2: เมตริกการประเมินผลสำหรับ LLM Travel Planning Agent

กลุ่มเมตริก	**ชื่อเมตริก**	**วัตถุประสงค์**	**กลไกการตรวจสอบ**
Feasibility & Rationality	Optimized Route	ลดเวลาการเดินทางระหว่าง POI	สคริปต์อัตโนมัติ (ผ่าน Map API)
	Non-conflicting Constraints	ตรวจสอบความขัดแย้งของลอจิสติกส์ (เช่น เวลาเปิด-ปิด, การขนส่ง)	Rule-based Validation
Completeness	Comprehensiveness (CPH)	แผนครอบคลุมทุกองค์ประกอบคำสั่งของผู้ใช้	Rule-based / LLM-assisted Evaluation
	Defined Budget Limit	ค่าใช้จ่ายรวมไม่เกินงบประมาณที่ระบุ	Automated Budget Tracking
Personalization	Individual Preference (PER)	วัดความสอดคล้องของแผนกับรสนิยมเฉพาะบุคคล	Human/LLM-assisted Evaluation (CRA)

บทสรุปและข้อเสนอแนะเชิงกลยุทธ์

การวิเคราะห์แสดงให้เห็นว่าความท้าทายหลักในการใช้ LLM เพื่อวางแผนการท่องเที่ยวที่มีประสิทธิภาพสูงในประเทศไทย ไม่ใช่เรื่องของการสร้างภาษา แต่เป็นเรื่องของความถูกต้องเชิงลอจิสติกส์และความสามารถในการจัดการข้อจำกัดเชิงปริมาณที่ซับซ้อน.

ข้อสรุปเชิงสังเคราะห์

1. **โมเดลสำเร็จรูปและการใช้งานในประเทศไทย (Goal 1):** แม้ว่าจะมีงานวิจัย LLM เฉพาะทางของไทย เช่น MAHASAMUT/PhuKhao LLM แต่การขาดข้อมูลที่ชัดเจนเกี่ยวกับลิขสิทธิ์เชิงพาณิชย์ทำให้เกิดความเสี่ยงทางกฎหมายที่สูง. **ข้อเสนอแนะที่ปลอดภัยที่สุด** คือการใช้โมเดลพื้นฐานสากล (Base Model) ที่มีลิขสิทธิ์แบบ Permissive (เช่น Apache 2.0) เป็นฐานในการพัฒนาผลิตภัณฑ์เชิงพาณิชย์ และใช้การ Fine-tune เพื่อการปรับตัวเข้ากับบริบทไทย

2. **ความจำเป็นทางสถาปัตยกรรม**: LLM ที่ปรับแต่งแล้วไม่สามารถทำงานได้ด้วยตัวเองในการวางแผนที่มีประสิทธิภาพสูง ต้องสร้าง **Hybrid Agent Architecture** ที่ใช้ LLM เป็น Reasoning Engine และผสานรวมกับ Optimization Algorithm และ Search Backends สำหรับการ Grounding ข้อมูลจริง. การปรับตัวเข้ากับบริบทไทยหมายถึงการผสานรวมอย่างแน่นหนาของ Agent Protocol กับ **TAT Data API** เพื่อดึงข้อมูล POI, กิจกรรม, และเส้นทางแนะนำที่เชื่อถือได้.

3. **กลยุทธ์ข้อมูลและการ Fine-Tuning (Goal 2 & 3):** ความสำเร็จของโครงการขึ้นอยู่กับการวิศวกรรมข้อมูล (Data Engineering) ที่เข้มข้น โดยเฉพาะการรวบรวมและแปลง **Structured Itineraries with Constraints** และ **POI/Knowledge Base Data** ให้เป็น Instruction Format (JSONL). การ Fine-tune ต้องใช้เทคนิค **PEFT/QLoRA** เพื่อความคุ้มค่าด้านทรัพยากร. การออกแบบชุดข้อมูล SFT ต้องเน้นการสอนให้ LLM สร้างผลลัพธ์ในรูปแบบที่มีโครงสร้างที่สามารถตรวจสอบความถูกต้องโดยอัตโนมัติได้ (Feasibility Checker) ซึ่งเป็นกุญแจสำคัญในการยกระดับประสิทธิภาพจาก 4% ให้สูงขึ้น.

ข้อเสนอแนะเชิงปฏิบัติการ

- **ด้านกฎหมายข้อมูล**: ทีมควรดำเนินการตรวจสอบและขอการยืนยันอย่างเป็นทางการเกี่ยวกับเงื่อนไขการใช้งานเชิงพาณิชย์ของ TAT Data API และ Open Government Data ของไทย. หากมีข้อจำกัดที่เข้มงวด ควรจำกัดการใช้ข้อมูลนี้สำหรับการ Grounding แบบเรียลไทม์ผ่าน API เท่านั้น.

- **ด้านการพัฒนา**: มุ่งเน้นการพัฒนา Agent Protocol เพื่อให้ LLM สามารถสร้าง Tool Calling ที่แม่นยำ. การ Fine-tune ควรเน้นไปที่การสร้างความสามารถในการจัดการข้อจำกัดและการสร้างผลลัพธ์ที่มีโครงสร้าง (Structured Output) เป็นหลัก.
- **ด้านการวัดผล**: ต้องใช้กรอบการประเมินผลที่เน้นไปที่ Plan Quality โดยเฉพาะมิติ Feasibility, Rationality, และ Optimization (Optimized Route, Non-conflicting Constraints) โดยใช้ระบบตรวจสอบอัตโนมัติที่แข็งแกร่ง.