**เอกสารข้อกำหนดระบบ (SSD) สำหรับระบบประเมินผลการออกแบบ UX/UI แบบหลายเอเจนต์**

## I. บทสรุปสำหรับผู้บริหารและเป้าหมาย

### I.1. วิสัยทัศน์และการจัดตำแหน่งเชิงกลยุทธ์

ระบบผู้ประเมินผลการออกแบบ UX/UI แบบหลายเอเจนต์ (The System) ถูกพัฒนาขึ้นเพื่อจัดการกับความท้าทายด้านความสามารถในการขยายขนาด (Scalability) และความสอดคล้อง (Consistency) ซึ่งเป็นปัญหาที่เกิดขึ้นซ้ำ ๆ ในกระบวนการประเมินงานออกแบบที่มีความซับซ้อนและหลากหลายรูปแบบในระดับอุดมศึกษา การประเมินผลโดยมนุษย์มักประสบกับความแตกต่างระหว่างผู้ประเมินและความล่าช้าในการให้ข้อเสนอแนะ การนำสถาปัตยกรรมระบบหลายเอเจนต์ (Multi-Agent System - MAS) มาใช้ ทำให้แพลตฟอร์มสามารถรับประกันการประยุกต์ใช้เกณฑ์การให้คะแนนเชิงการสอนอย่างสม่ำเสมอ เพิ่มความเป็นกลางในการให้คะแนน และลดความล่าช้าในการให้ข้อเสนอแนะได้อย่างมาก 。

ระบบนี้ไม่เพียงแต่ให้คะแนนเท่านั้น แต่ยังให้ข้อมูลเชิงลึกที่ขับเคลื่อนด้วยข้อมูล (Data-driven insights) เกี่ยวกับประสิทธิภาพของนักศึกษาเมื่อเทียบกับมาตรฐาน UX/UI ที่กำหนด เช่น หลักการพิจารณา 10 ข้อของ Nielsen (Neilsen's 10 Heuristics) การทำงานนี้สนับสนุนพันธกิจของสถาบันในการส่งเสริม "การตัดสินใจโดยใช้ข้อมูลจาก AI" (AI-Informed Decision-Making) และการเรียนรู้แบบเฉพาะบุคคล (Personalized Learning) อย่างมีประสิทธิภาพ 。

### I.2. ความสามารถระดับสูงและบทบาทของเอเจนต์

ระบบใช้สถาปัตยกรรมแบบรวมศูนย์ (Centralized Architecture) ที่มีเอเจนต์ผู้ประสานงาน (Orchestrator Agent หรือ A4) เป็นศูนย์กลางในการจัดการ เอเจนต์ผู้เชี่ยวชาญเฉพาะทางสามตัว (A1, A2, และ A3) จะดำเนินการประเมินผลแบบขนาน (Parallel Execution) เพื่อเพิ่มประสิทธิภาพและความรวดเร็วในการทำงาน 。

| **เอเจนต์** | **บทบาทและจุดเน้นหลัก** |
|---|---|
| **A1: User Analysis Expert (UA-Agent)** | ตรวจสอบความถูกต้องของสิ่งประดิษฐ์งานวิจัยผู้ใช้ (Persona, Empathy Map) ในด้านความลึก ความสมจริง และความสอดคล้องกับวัตถุประสงค์โครงการ |

| เอเจนต์ | บทบาทและจุดเน้นหลัก |
|---|---|
| **A2: Heuristics & Principle Expert (HP-Agent)** | สแกนและประเมินสิ่งประดิษฐ์งานออกแบบ (Prototype) เทียบกับกฎและหลักการ UX ที่กำหนดไว้ (เช่น Heuristics, Fitts's Law) |
| **A3: Structure & Flow Expert (SF-Agent)** | ตรวจสอบตรรกะ ประสิทธิภาพ และความสมบูรณ์ของสถาปัตยกรรมข้อมูล (Sitemap) และเส้นทางผู้ใช้ (Journey, Story Mapping) |
| **A4: Orchestrator & Reporting Agent (O/R-Agent)** | จัดการเวิร์กโฟลว์ สังเคราะห์ผลการประเมินทั้งหมด คำนวณเกรดสุดท้าย และสร้างรายงานฉบับสมบูรณ์ |

### I.3. ภาพรวมตัวชี้วัดความสำเร็จของโครงการ

ตัวชี้วัดความสำเร็จของโครงการไม่ได้จำกัดอยู่เพียงแค่ปริมาณงานประมวลผล แต่เน้นที่ความน่าเชื่อถือทางด้านการสอน (Pedagogical Reliability) เป็นหลัก โดยมีเป้าหมายสำคัญคือ **ความสอดคล้องในการให้คะแนน (Grading Consistency)** และ **คุณภาพของข้อเสนอแนะ (Feedback Quality)** ตัวชี้วัดประสิทธิภาพหลัก (KPIs) จะถูกกำหนดขึ้นเพื่อเปรียบเทียบประสิทธิภาพของระบบกับผู้เชี่ยวชาญที่เป็นมนุษย์ (Subject Matter Experts - SMEs) เพื่อสร้างความมั่นใจในความถูกต้องและน่าเชื่อถือของการประเมินผลโดยอัตโนมัติ 。

## II. สถาปัตยกรรมระบบและกระบวนการทำงาน

### II.A. ภาพรวมสถาปัตยกรรม MAS แบบรวมศูนย์

สถาปัตยกรรมที่นำเสนอคือ **รูปแบบผู้กำกับดูแล/ผู้ประสานงานแบบรวมศูนย์ (Centralized Supervisor/Orchestrator Pattern)** 。 รูปแบบนี้เป็นที่ยอมรับในระบบที่ต้องการการประสานงานที่แม่นยำและการจัดการกระแสการสื่อสารที่เข้มงวด ซึ่งมีความสำคัญอย่างยิ่งสำหรับระบบการให้คะแนนทางวิชาการที่ต้องการความสม่ำเสมอของผลลัพธ์ 。

#### 1. บทบาทของ A4 ในฐานะผู้กำกับดูแล

A4 (O/R-Agent) ทำหน้าที่เป็นศูนย์กลางการควบคุม โดยรับผิดชอบในการมอบหมายงาน (Task Delegation) การรักษาบริบทที่ใช้ร่วมกัน (Shared Context) และการรวมผลลัพธ์ การควบคุมแบบรวมศูนย์นี้ช่วยให้มั่นใจได้ว่า

เอเจนต์เฉพาะทางแต่ละตัวจะทำงานตามบทบาทที่กำหนดและป้องกันความเสี่ยงของการทำงานที่วุ่นวาย (chaotic multi-bot pile-on) ซึ่งอาจเกิดขึ้นในระบบที่มีการเชื่อมต่อแบบหลวม ๆ ๐

**2. การแยกส่วนของความเชี่ยวชาญ (Decoupled Specialization)**

เอเจนต์ผู้เชี่ยวชาญ (A1, A2, A3) ถูกออกแบบมาให้ทำงานกึ่งอิสระ โดยใช้แกนโมเดลภาษาขนาดใหญ่ (LLM Core) หรือขนาดเล็ก (SLM Core) พร้อมชุดเครื่องมือเฉพาะทางของตนเอง สิ่งสำคัญคือ เอเจนต์เหล่านี้จะรายงานเฉพาะผลการประเมินที่ถูกจัดโครงสร้างอย่างเป็นมาตรฐานกลับไปยัง A4 ผ่านรูปแบบ JSON Schema ที่กำหนดไว้เท่านั้น สิ่งนี้ทำให้ A4 สามารถควบคุมการประมวลผลและการให้คะแนนได้อย่างสม่ำเสมอ

**3. การจัดการความเสี่ยงของจุดเดียวในการล้มเหลว (SPOF)**

การนำรูปแบบรวมศูนย์มาใช้ย่อมก่อให้เกิดจุดเดียวในการล้มเหลว (Single Point of Failure - SPOF) ที่ A4 ความเสี่ยงนี้ได้รับการบรรเทาโดยการติดตั้ง A4 ในรูปแบบไมโครเซอร์วิส (Microservice) ที่มีความพร้อมใช้งานสูง (High Availability) และบูรณาการเข้ากับคิวงานที่ทนทานต่อความล้มเหลว (เช่น Kafka หรือ RabbitMQ) เพื่อให้มั่นใจว่าการมอบหมายและการประมวลผลงานจะมีความต่อเนื่องและการลองใหม่ (Retries) ในกรณีที่เกิดความขัดข้องชั่วคราว ซึ่งเป็นสิ่งจำเป็นอย่างยิ่งในสภาพแวดล้อม EdTech ที่ต้องใช้งานจริง ๐

**II.B. แผนภาพกระบวนการทำงาน: การส่งงานสู่การสังเคราะห์**

กระบวนการทำงานถูกออกแบบมาให้มีความเป็นลำดับขั้นตอน แต่มีส่วนที่สำคัญที่สุดคือการดำเนินการแบบขนาน (Synchronous Parallel Execution) เพื่อลดความหน่วงเวลาและเพิ่มประสิทธิภาพในการให้ข้อเสนอแนะแก่นักศึกษา ความสามารถในการดำเนินการแบบขนานนี้เป็นหัวใจสำคัญที่ทำให้ระบบสามารถให้ข้อเสนอแนะได้ทันที เนื่องจากสามารถวิเคราะห์งานที่หลากหลาย (ข้อความ, ลิงก์ Figma, แผนภาพ) พร้อมกันได้ ก่อนที่ผลลัพธ์จะถูกรวมเข้าด้วยกันในขั้นตอนสุดท้ายโดย A4

ตารางที่ 1: ขั้นตอนกระบวนการทำงานของระบบ (Submission to Synthesis Workflow)

| ขั้นตอน | ระยะ | เอเจนต์ที่เกี่ยวข้อง | คำอธิบาย |
|---|---|---|---|
| **1.** การนำเข้า (**Ingestion)** | Input Handling | Submission Gateway | นักศึกษาส่งสิ่งประดิษฐ์ (เอกสารข้อความ, ลิงก์ Figma/Web) ระบบตรวจสอบความถูกต้องของไฟล์ จัดเก็บอย่างปลอดภัย และแยกข้อมูลเมตา (ID นักศึกษา, ID งาน) |
| **2.** การตรวจสอบ (**Validation)** | Parsing & Preparation | Submission Gateway, A4 | แยกวิเคราะห์สิ่งประดิษฐ์ A4 ตรวจสอบความสมบูรณ์ของลิงก์/ไฟล์ และสร้างรูปแบบอินพุตที่เป็นมาตรฐานสำหรับเอเจนต์ผู้เชี่ยวชาญ |
| **3.** การมอบหมายงาน (**Delegation)** | Orchestration | A4 (O/R-Agent) | A4 วิเคราะห์ข้อกำหนดการให้คะแนนและมอบหมายงาน/อินพุตที่เกี่ยวข้องไปยัง A1, A2, และ A3 เพื่อดำเนินการ **แบบขนานพร้อมกัน** |
| **4.** การวิเคราะห์และประเมินผล | Parallel Execution | A1, A2, A3 | เอเจนต์เฉพาะทางดำเนินการวิเคราะห์เชิงลึกและการเรียกใช้เครื่องมือ A1 วิเคราะห์ Persona/Empathy (ความสมจริง) A2 ใช้ Tool Stack (API/CV) ประเมิน Heuristics/Prototype A3 ตรวจสอบตรรกะเชิงโครงสร้าง (IA/Journey) |
| **5.** การรายงานผลแบบมีโครงสร้าง | Communication | A1, A2, A3 | เอเจนต์แต่ละตัวสร้างรายการข้อค้นพบ (Violations, Recommendations) และจัดรูปแบบข้อมูลตาม JSON Schema ที่กำหนดไว้อย่างเคร่งครัด |

| ขั้นตอน | ระยะ | เอเจนต์ที่เกี่ยวข้อง | คำอธิบาย |
|---|---|---|---|
| **6. การสังเคราะห์และการให้คะแนน** | Aggregation | A4 (O/R-Agent) | A4 รวบรวมรายงาน JSON ที่จัดโครงสร้างทั้งหมด นำตรรกะการให้คะแนนแบบถ่วงน้ำหนัก (ส่วนที่ V.A/B) มาใช้เพื่อคำนวณการหักคะแนนตามระดับความรุนแรง |
| **7. การสร้างรายงาน** | Output | A4 (O/R-Agent) | A4 สังเคราะห์คะแนนรวมและข้อเสนอแนะให้เป็นรายงานเชิงการสอนที่อ่านง่ายและเป็นทางการสำหรับนักศึกษา รวมถึงเกรดสุดท้ายและคำแนะนำที่นำไปปฏิบัติได้ |
| **8. การจัดเก็บและการบันทึก** | Storage | Core Service | เกรดสุดท้าย รายงานโดยละเอียด และการสื่อสารของเอเจนต์ทั้งหมดจะถูกบันทึกไว้สำหรับการตรวจสอบ การเปรียบเทียบมาตรฐาน และการฝึกอบรมโมเดลในอนาคต |

**III. รายละเอียดจำเพาะของเอเจนต์**

เอเจนต์แต่ละตัวถูกกำหนดให้มีความเชี่ยวชาญเฉพาะด้านตามหลักสูตร UX/UI เพื่อให้การวิเคราะห์มีความแม่นยำและลึกซึ้งสูงสุด ๐

### III.A. A1: ผู้เชี่ยวชาญด้านการวิเคราะห์ผู้ใช้ (UA-Agent)

A1 มีหน้าที่รับผิดชอบในการประเมินสิ่งประดิษฐ์งานวิจัยผู้ใช้เชิงคุณภาพ โดยเน้นที่การวิเคราะห์เอกสารข้อความ A1 ใช้ Natural Language Understanding (NLU) และกราฟความรู้เฉพาะโดเมน (Domain-specific knowledge graphs) เพื่อประเมินความสมจริง ความลึก และความสอดคล้องของโปรไฟล์ผู้ใช้ สิ่งนี้สำคัญในการตรวจสอบว่านักศึกษาได้ทำการวิจัยอย่างเพียงพอหรือไม่ โดยหลีกเลี่ยงการใช้ Persona ที่เป็นเพียงการคาดเดาหรือขาดหลักฐานเชิงพฤติกรรมที่ชัดเจน

- **พื้นที่เป้าหมาย**: ความสมจริง ความลึก ความสม่ำเสมอของคุณลักษณะของผู้ใช้ และความสอดคล้องระหว่างความต้องการของ Persona กับจุดบกพร่องที่ระบุใน Empathy Map
- **ฟังก์ชันเฉพาะทาง**: ประเมินว่า Persona มีคุณลักษณะเชิงพฤติกรรมที่วัดปริมาณได้หรือไม่ (quantifiable behavioral attributes) และ Empathy Map แสดงถึงความเข้าใจอย่างลึกซึ้งในความคิด (Think), ความรู้สึก (Feel) และการกระทำ (Do) ของผู้ใช้เป้าหมายอย่างแท้จริง
- **รูปแบบเอาต์พุต**: รายงานการละเมิด JSON ที่ระบุความไม่สอดคล้องหรือความตื้นเขินของการวิจัยผู้ใช้ เช่น "Persona ขาดคุณลักษณะเชิงพฤติกรรมที่วัดปริมาณได้"

### III.B. A2: ผู้เชี่ยวชาญด้านฮิวริสติกและหลักการ (HP-Agent)

A2 เป็นเอเจนต์ที่ต้องใช้เครื่องมือหลายรูปแบบ (Multimodal Tooling) ที่ซับซ้อนที่สุด เนื่องจากต้องทำการวิเคราะห์ทางเทคนิคของต้นแบบดิจิทัล (Prototype) เพื่อตรวจสอบความสามารถในการใช้งาน (Usability) การเข้าถึง (Accessibility) และความสอดคล้องของแบรนด์ (Brand Consistency) การวิเคราะห์นี้ต้องเปลี่ยนจากการประเมินเชิงแนวคิดไปสู่การตรวจสอบการออกแบบทางกายภาพ (Physical Design Verification)

- **พื้นที่เป้าหมาย**: หลักการพิจารณา 10 ข้อของ Nielsen (โดยเฉพาะ Visibility, Consistency, Error Prevention), กฎ UX (เช่น Fitts's Law, Hick's Law, Affordance) และการยึดมั่นใน Brand & Tone
- **ความซับซ้อน**: A2 จำเป็นต้องเข้าถึงข้อมูลเชิงลึกขององค์ประกอบการออกแบบ เช่น ค่าสี ขนาด และตำแหน่ง เพื่อคำนวณอัตราส่วนคอนทราสต์ของ WCAG (Web Content Accessibility Guidelines) และวัดระยะห่างระหว่างองค์ประกอบเชิงโต้ตอบสำหรับ Fitts's Law (ดูส่วน IV.A)
- **รูปแบบเอาต์พุต**: รายงานการละเมิด JSON ที่เชื่อมโยงองค์ประกอบหน้าจอที่เฉพาะเจาะจง (เช่น Element ID หรือ Bounding Box Coordinates) กับหลักการที่ถูกละเมิด (เช่น "วิกฤต: ความล้มเหลวของอัตราส่วนคอนทราสต์ (WCAG), Heuristic 10/Accessibility")

### III.C. A3: ผู้เชี่ยวชาญด้านโครงสร้างและกระแสการทำงาน (SF-Agent)

A3 มุ่งเน้นไปที่ความสมบูรณ์เชิงตรรกะและประสิทธิภาพของโครงสร้างข้อมูลและการนำทาง การวิเคราะห์ของ A3 เป็นการยืนยันว่าโครงสร้างพื้นฐานของประสบการณ์ผู้ใช้นั้นมีเหตุผลและครบถ้วน ก่อนที่ A2 จะทำการประเมินการออกแบบการโต้ตอบ

- **พื้นที่เป้าหมาย**: ตรรกะของสถาปัตยกรรมข้อมูล (IA), ประสิทธิภาพของการนำทาง, ความครบถ้วนของเส้นทางผู้ใช้เพื่อให้บรรลุเป้าหมายหลัก และความเป็นไปได้ของขอบเขตงาน (การตรวจสอบ "Feature Creep" หรือการกำหนดขอบเขตที่น้อยเกินไป)
- **ฟังก์ชันเฉพาะทาง**: ใช้อัลกอริทึมการแยกวิเคราะห์กราฟ (Graph Parsing Algorithms) สำหรับ Sitemap และตรรกะการเปลี่ยนสถานะ (State-transition Logic) สำหรับ User Journey เพื่อตรวจสอบว่าเส้นทางที่วางแผนไว้นั้นเป็นไปอย่างเหมาะสม และครอบคลุมทุกสถานะที่จำเป็นของระบบ
- **รูปแบบเอาต์พุต**: รายงานการละเมิด JSON ที่เน้นข้อผิดพลาดเชิงโครงสร้าง เช่น "สำคัญ: พบทางตันใน User Journey สำหรับเส้นทาง 'การชำระเงิน'"

### III.D. A4: ผู้ประสานงานและผู้สร้างรายงาน (O/R-Agent)

A4 เป็นกลไกหลักของระบบการให้คะแนน (Grade Engine) โดยรับบทบาทเป็นผู้ควบคุมวงออร์เคสตรา แต่ไม่ได้ทำการวิเคราะห์โดเมนด้วยตนเอง ความชาญฉลาดของ A4 อยู่ในการประสานงานและการประยุกต์ใช้ระเบียบการให้คะแนนเชิงคณิตศาสตร์อย่างสม่ำเสมอ

- **ความรับผิดชอบหลัก**:
    1. **การจัดการงาน**: มอบหมายงานไปยัง A1, A2, A3 และรักษาบริบทการส่งงานที่ใช้ร่วมกัน
    2. **การสังเคราะห์**: รวบรวมผลการค้นพบ JSON ที่จัดโครงสร้างทั้งหมดจากเอเจนต์ผู้เชี่ยวชาญ
    3. **การคำนวณเกรด**: ประยุกต์ใช้แบบจำลองการให้คะแนนแบบถ่วงน้ำหนัก (ส่วนที่ V) เพื่อหักคะแนนตามระดับความรุนแรงของการละเมิดที่รายงาน
    4. **การสร้างรายงาน**: แปลงผลการให้คะแนนที่จัดโครงสร้างให้เป็นรายงานข้อเสนอแนะเชิงการสอนที่มีความเป็นมืออาชีพและนำไปปฏิบัติได้

## IV. สแตกเทคนิคและแบบจำลองข้อมูล

### IV.A. การพิสูจน์และการผสานรวมเครื่องมือ A2

การให้คะแนนการออกแบบ UI/UX อย่างเป็นกลางจำเป็นต้องมีการวิเคราะห์ที่ละเอียดอ่อนเกินกว่าความสามารถของโมเดลภาษาขนาดใหญ่ (LLM) ทั่วไป การประเมินกฎหมาย UX ที่สำคัญ เช่น อัตราส่วนคอนทราสต์ตาม WCAG และการวัดระยะห่างเพื่อประเมิน Fitts's Law จำเป็นต้องใช้เครื่องมือภายนอกที่เฉพาะเจาะจง การใช้ชุดเครื่องมือหลายรูปแบบนี้ช่วยเพิ่มความน่าเชื่อถือเชิงวัตถุวิสัย (Objective Credibility) ให้กับเกรดอัตโนมัติ

การวิเคราะห์ต้นแบบการออกแบบ (เช่น Figma หรือ Web Link) เกี่ยวข้องกับการเข้าถึงข้อมูลสองประเภท: ข้อมูลเชิงประกาศ (Declarative Data) และข้อมูลที่แสดงผล (Rendered Visual Data)

1. **การวิเคราะห์ข้อมูลเชิงประกาศ**: ใช้ **Figma REST API** เพื่อดึง Design Tokens (สี, ฟอนต์, สัดส่วน) และโครงสร้าง JSON ของเลเยอร์ องค์ประกอบเหล่านี้ช่วยในการตรวจสอบความสอดคล้องของ Brand & Tone และการตั้งชื่อเลเยอร์ที่เหมาะสม (Affordance)
2. **การวิเคราะห์ข้อมูลที่แสดงผล**: ใช้ **เครื่องมือตรวจสอบ WCAG** และ **Computer Vision (CV)**

การใช้ CV (เช่น โมเดลตรวจจับวัตถุ) นั้นจำเป็นเมื่อการเข้าถึง API ไม่สมบูรณ์ หรือเพื่อประเมินคุณสมบัติทางกายภาพของหน้าจอที่แสดงผล เช่น การวัดระยะห่างระหว่างปุ่มเพื่อประมาณ Fitts's Law หรือการประเมินการจัดองค์ประกอบภาพและน้ำหนักเชิงสายตา (Visual Weight)

ตารางที่ 2: สแตกเครื่องมือสำหรับ A2 (HP-Agent)

| **หมวดหมู่เครื่องมือ** | **วัตถุประสงค์หลัก** | **ฟังก์ชันที่สำคัญ** | **หลักการ UX ที่เกี่ยวข้อง** |
|---|---|---|---|
| **Figma REST API / Web Parser** | ดึงข้อมูลโทเคนการออกแบบ (Design Tokens) และโครงสร้างองค์ประกอบเพื่อตรวจสอบความสอดคล้องของ Brand & Tone | การแยกสไตล์, การระบุ ID โหนด Figma, การตรวจสอบลำดับชั้นขององค์ประกอบ | Brand & Tone Consistency |

| หมวดหมู่เครื่องมือ | วัตถุประสงค์หลัก | ฟังก์ชันที่สำคัญ | หลักการ UX ที่เกี่ยวข้อง |
|---|---|---|---|
| **WCAG Accessibility Checkers** | คำนวณอัตราส่วนคอนทราสต์ของความสว่างตาม WCAG 2.1 ระดับ AA และตรวจจับความบกพร่องทางความเข้าถึง | การคำนวณคอนทราสต์สี, การตรวจสอบสถานะการโฟกัส, การระบุ ARIA attributes | Nielsen H. 10 (Accessibility), WCAG 2.1 |
| **Computer Vision (CV)** | วิเคราะห์สถานะภาพที่แสดงผลเพื่อยืนยันกฎการจัดวางและหลักการเชิงกายภาพ | การตรวจจับวัตถุเชิงโต้ตอบ, การวัดระยะห่างเชิงพื้นที่ (Fitts's Law Approximation), การประเมินน้ำหนักเชิงสายตา | Fitts's Law, Affordance |
| **LLM Core (Synthesis Layer)** | ตีความข้อมูลเชิงปริมาณที่รวบรวมได้ และสังเคราะห์ Violation_Description และ Actionable_Recommendation เชิงการสอน | การสังเคราะห์ข้อมูลเชิงลึก, การสร้างภาษาธรรมชาติสำหรับข้อเสนอแนะ | Feedback Quality |

**IV.B. แบบแผนข้อมูลสำหรับการสื่อสารของเอเจนต์ (JSON Schema)**

การกำหนดให้เอเจนต์ทั้งหมด (A1, A2, A3) ใช้โครงสร้างข้อมูล JSON ที่เป็นมาตรฐานและเคร่งครัดเป็นสิ่งจำเป็นเพื่อรับประกันความสามารถในการทำงานร่วมกัน (Interoperability) และความถูกต้องของข้อมูลที่ A4 จะนำไปประมวลผล การใช้ JSON Schema ช่วยให้ข้อมูลข้อเสนอแนะทั้งหมดเป็น **ข้อมูลที่นำไปปฏิบัติได้ (Actionable)** และ **วัดปริมาณได้ (Quantifiable)** ซึ่งมีความสำคัญต่อการวิเคราะห์ข้อมูลในระยะยาวเพื่อระบุจุดบกพร่องทางความรู้ที่พบบ่อยในหลักสูตร (Pedagogical Deficits)

โครงสร้างข้อมูล Feedback_Violation กำหนดให้ต้องมีฟิลด์บังคับเพื่อเชื่อมโยงการประเมินเชิงคุณภาพ (คำอธิบายการละเมิด) เข้ากับการประเมินเชิงปริมาณ (ระดับความรุนแรงและน้ำหนักการหักคะแนน)

JSON Schema Structure: Feedback_Violation

JSON

```
{
  "$schema": "http://json-schema.org/draft-2020-12/schema",
  "$id": "https://edtech.university/schemas/ux_violation_report_v1.json",
  "title": "UX/UI Grader Agent Violation Report",
  "type": "object",
  "properties": {
    "Report_ID": {
      "type": "string",
      "description": "Unique identifier for this specific violation instance."
    },
    "Agent_Source": {
      "type": "string",
      "enum":,
      "description": "The specialized agent that reported the violation."
    },
    "Topic_ID": {
      "type": "string",
      "description": "Pedagogical topic or criterion violated (e.g., HP-1.3 for Consistency Heuristic)."
    },
    "Violation_Description": {
      "type": "string",
      "description": "Detailed explanation of the flaw, referencing specific design artifacts or screen locations."
    },
    "Severity_Rating": {
```

"type": "integer",

"description": "The impact level of the violation (3=Critical, 2=Major, 1=Minor, 0=Informational).",

"enum":

},

"Actionable_Recommendation": {

"type": "string",

"description": "Specific, practical step the student must take to resolve the violation."

},

"Score_Deduction_Weight": {

"type": "number",

"description": "The calculated weight multiplier associated with the Severity_Rating (used by A4 for deduction)."

},

"Evidence_Context": {

"type": "object",

"description": "Structured data proving the violation (e.g., WCAG contrast value, URL/Screen name, Figma Node ID)."

}

},

"required":

}

## V. เมตริกการประเมินและตรรกะการให้คะแนน

### V.A. แบบจำลองการให้คะแนนถ่วงน้ำหนักและเกณฑ์การจัดสรร

คะแนนรวมของงานนี้คือ 100 คะแนน การจัดสรรน้ำหนักสะท้อนถึงลำดับความสำคัญของหลักสูตร โดยเน้นที่ความสำคัญของงานวิจัยพื้นฐาน (A1) และการดำเนินการทางเทคนิคของความสามารถในการใช้งาน (A2) เพื่อให้

เกิดความสมดุล การให้น้ำหนักสูงแก่ Heuristics (30%) และ Prototype (25%) เป็นการยืนยันว่าผลิตภัณฑ์ขั้นสุดท้ายจะต้องสามารถใช้งานได้จริงและเป็นไปตามมาตรฐานที่เข้มงวด

ตารางที่ 3: เกณฑ์การจัดสรรน้ำหนักการให้คะแนน (คะแนนรวม 100 คะแนน)

| **ID** | **หัวข้อหลัก (เกณฑ์การประเมิน)** | **เอเจนต์ที่เกี่ยวข้อง** | **น้ำหนักพื้นฐานที่เสนอ (%)** | **คะแนน (100)** |
|---|---|---|---|---|
| 1.0 | Neilsen's 10 Heuristics & UX Principles | A2 (HP-Agent) | 30% | 30 |
| 2.0 | Prototype (Interaction & Usability) | A2 (HP-Agent) | 25% | 25 |
| 3.0 | Persona | A1 (UA-Agent) | 10% | 10 |
| 4.0 | Empathy Map | A1 (UA-Agent) | 10% | 10 |
| 5.0 | User Journey & Scoping | A3 (SF-Agent) | 10% | 10 |
| 6.0 | User Story Mapping | A3 (SF-Agent) | 5% | 5 |
| 7.0 | Sitemap (Information Architecture) | A3 (SF-Agent) | 5% | 5 |
| 8.0 | Brand & Tone (Consistency) | A2 (HP-Agent) | 5% | 5 |
| **รวม** | **9 หัวข้อหลัก** | | **100%** | **100** |

**V.B. ตรรกะการแมปความรุนแรงสู่การหักคะแนน**

เอเจนต์ O/R (A4) แปลงระดับความรุนแรงเชิงประเภท (Severity_Rating) ที่ได้รับจาก A1, A2, และ A3 ให้เป็นการหักคะแนนเชิงปริมาณโดยใช้ตัวคูณมาตรฐานที่กำหนดไว้ การออกแบบนี้เลียนแบบแบบจำลองการให้คะแนนข้อบกพร่อง (Bug Scoring) ในระบบการประกันคุณภาพ (QA) เพื่อให้การหักคะแนนมีความเป็นระบบและมีเหตุผลเชิงคณิตศาสตร์

ตรรกะการหักคะแนนใช้สูตร:

$$\text{Deduction (Points)} = \text{Deduction Multiplier} \times (\text{Base Weight} / \text{Expected Instances})$$

*หมายเหตุ: คะแนนหักรวมสูงสุดสำหรับแต่ละหัวข้อจะถูกจำกัดไว้ที่น้ำหนักคะแนนพื้นฐานของหัวข้อนั้น (เช่น 30 คะแนนสำหรับ Heuristics)*

ตารางที่ 4: ระดับความรุนแรงและตัวคูณการหักคะแนน

| **ระดับความรุนแรง** | **ระดับ** | **คำจำกัดความ (ผลกระทบ)** | **ตัวคูณการหักคะแนน (Base Weight Factor)** |
|---|---|---|---|
| **3** | **Critical (วิกฤต)** | ความล้มเหลวโดยสมบูรณ์ของฟังก์ชันหลักของระบบ หรือการละเมิดกฎหมายกลางอย่างร้ายแรง (เช่น WCAG Level A failure หรือทำให้เส้นทางผู้ใช้หยุดชะงัก) | **2.5x** |
| **2** | **Major (สำคัญ)** | ปัญหาความสามารถในการใช้งานที่สำคัญ ความไม่สอดคล้องอย่างรุนแรง หรือการประยุกต์ใช้หลักการสำคัญที่อ่อนแอซึ่งต้องใช้วิธีแก้ปัญหาสำรอง (Workaround) (เช่น การนำทางที่ไม่สอดคล้อง) | **1.5x** |
| **1** | **Minor (เล็กน้อย)** | ปัญหาด้านสุนทรียภาพ แรงเสียดทานเล็กน้อย หรือข้อผิดพลาดผิวเผินที่ไม่ส่งผลกระทบต่อการทำงานหลัก (เช่น ปัญหาการจัดตำแหน่งเล็กน้อย) | **0.5x** |
| **0** | **Informational (ข้อมูล)** | ข้อเสนอแนะสำหรับการปรับปรุงสไตล์หรือคำแนะนำแนวทางปฏิบัติที่ดีที่สุด (Best Practice) | **0x** |

**V.C. ตัวชี้วัดประสิทธิภาพหลัก (KPIs)**

เพื่อให้มั่นใจว่าระบบไม่เพียงแต่ทำงานได้ แต่ยังให้ผลลัพธ์ที่มีคุณภาพและน่าเชื่อถือในบริบทของการศึกษา ตัวชี้วัดประสิทธิภาพหลักสามตัวจึงถูกกำหนดขึ้น โดยเน้นที่ความน่าเชื่อถือทางสถิติและคุณค่าทางการสอน

ตารางที่ 5: ตัวชี้วัดประสิทธิภาพหลัก (KPIs) ของระบบ

| KPI | คำจำกัดความและเป้าหมาย | ระเบียบวิธีการวัด |
|---|---|---|
| **1. Grading Consistency (IRR)** | วัดความสอดคล้องระหว่างคะแนนของระบบกับคะแนนเอกฉันท์ของผู้เชี่ยวชาญที่เป็นมนุษย์ (SMEs) เป้าหมาย: QWK $\ge 0.80$ (ข้อตกลงที่แข็งแกร่ง) | คำนวณโดยใช้ **Quadratic Weighted Kappa (QWK)** ซึ่งจำเป็นสำหรับคะแนนเชิงอันดับ (Ordinal Scale) ที่ให้น้ำหนักกับการไม่เห็นด้วยในระดับมาก |
| **2. Feedback Relevance Score (FRS)** | วัดประโยชน์ใช้สอยและความสามารถในการนำไปปฏิบัติของข้อเสนอแนะที่สร้างขึ้น ประเมินโดยการสำรวจนักศึกษาหรือการตรวจสอบโดย SMEs เป้าหมาย: FRS $\ge 4.0$ (จากมาตราส่วน 5.0 Likert) | SMEs ประเมินรายงานตัวอย่างของ A4 โดยใช้เกณฑ์ด้านความเฉพาะเจาะจง ความชัดเจน และการยึดมั่นในองค์ประกอบของข้อเสนอแนะคุณภาพสูง (เช่น EFeCT Criteria) |
| **3. Automated Grading Coverage Rate (AGCR)** | วัดเปอร์เซ็นต์ของเกณฑ์การประเมินหลัก (9 หัวข้อ) ที่เป็นอัตโนมัติโดยสมบูรณ์โดยไม่ต้องการการแทรกแซงจากมนุษย์ เป้าหมาย: AGCR $\ge 95\%$ | คำนวณเป็นอัตราส่วนของการหักคะแนนอัตโนมัติเทียบกับคะแนนหักทั้งหมดที่เป็นไปได้ ติดตามการพึ่งพาการแก้ไขด้วยตนเองของระบบ |

**V.D. ระเบียบวิธีตรวจสอบความถูกต้องและเปรียบเทียบมาตรฐาน**

การตรวจสอบความถูกต้องอย่างเข้มงวดเป็นสิ่งจำเป็นในการสร้างความไว้วางใจเชิงการสอนในระบบอัตโนมัติ

**1. การกำหนดกลุ่มตรวจสอบความถูกต้อง (Validation Cohort):**

จะมีการจัดตั้งกลุ่มผู้เชี่ยวชาญเฉพาะทาง (SMEs) อิสระ **N $\ge$ 5** คน (คณาจารย์มหาวิทยาลัยหรือผู้เชี่ยวชาญด้านการออกแบบในอุตสาหกรรม) เพื่อให้คะแนนชุดข้อมูลอ้างอิงของงานที่ส่งโดยนักศึกษา **M $\ge$ 50** งาน

**2. การสร้างคะแนนเอกฉันท์ (Consensus Grading):**

คะแนนที่ได้รับจาก SMEs มนุษย์จะถูกรวบรวมเพื่อสร้าง 'Reference Grade' หรือ 'Human Consensus Score' ก่อนอื่นต้องวัดความน่าเชื่อถือระหว่างผู้ประเมินที่เป็นมนุษย์ด้วยกันเอง (Inter-Rater Reliability) โดยใช้ Fleiss' Kappa หรือ QWK เพื่อให้แน่ใจว่าคะแนนพื้นฐานของมนุษย์มีความน่าเชื่อถือ

**3. การวัดความน่าเชื่อถือ**: **Quadratic Weighted Kappa (QWK):**

ตัวชี้วัดหลักสำหรับการตรวจสอบความถูกต้องคือ **Quadratic Weighted Kappa (QWK)** QWK ถูกเลือกเนื่องจากมีความเหนือกว่า Cohen's Kappa มาตรฐานในการให้คะแนนเชิงวิชาการ โดยจะลงโทษการไม่เห็นด้วยในระดับมากอย่างรุนแรงกว่า (เช่น คะแนนที่แตกต่างกันมากระหว่างระบบกับผู้เชี่ยวชาญ) ซึ่งเป็นสิ่งสำคัญอย่างยิ่งในบริบทของการให้เกรดเชิงอันดับ (Ordinal Grading) ที่ความผิดพลาดในการจัดประเภท (เช่น การให้เกรดตกแก่นักศึกษาที่ควรได้เกรดผ่าน) มีผลกระทบทางการศึกษาอย่างมาก

**ขั้นตอนระเบียบวิธี**:

1. นำงานส่ง M ชิ้นเข้าสู่ The System เพื่อสร้างชุดข้อมูล 'System Grade'
2. เปรียบเทียบ 'System Grade' กับ 'Human Consensus Score' (หรือเทียบกับคะแนน SMEs แต่ละคน)
3. คำนวณคะแนน QWK เพื่อหาปริมาณข้อตกลงที่นอกเหนือไปจากความบังเอิญ
4. **เกณฑ์การเปรียบเทียบมาตรฐาน (Benchmarking Threshold):** ระบบจะถือว่าพร้อมสำหรับการใช้งานจริงหากคะแนน QWK เมื่อเทียบกับ Human Consensus เท่ากับหรือสูงกว่าคะแนน QWK ที่สังเกตได้ภายในกลุ่ม SMEs มนุษย์ ซึ่งบ่งชี้ว่าประสิทธิภาพของระบบเทียบเท่าหรือดีกว่าผู้เชี่ยวชาญมนุษย์แต่ละคนในทางสถิติ

**4. การเพิ่มประสิทธิภาพหลังการเปรียบเทียบมาตรฐาน**:

ข้อมูลประสิทธิภาพเริ่มต้นจะถูกนำไปใช้ในเซสชันการติดฉลาก (Labeling Sessions) เพื่อให้ข้อเสนอแนะในรูปแบบภาษาธรรมชาติแก่ O/R-Agent ซึ่งจะช่วยให้สามารถปรับปรุงการประสานงานของเอเจนต์และอัลกอริทึมการคำนวณเกรดได้อย่างต่อเนื่อง

## VI. บทสรุปและข้อเสนอแนะ

การวิเคราะห์ระบบผู้ประเมินผล UX/UI แบบหลายเอเจนต์นี้ได้ข้อสรุปว่า การออกแบบระบบในรูปแบบ **Centralized Supervisor/Orchestrator** เป็นสถาปัตยกรรมที่เหมาะสมที่สุดสำหรับการให้คะแนนงานออกแบบเชิงวิชาการที่มีความซับซ้อน เนื่องจากช่วยให้การจัดสรรงานเฉพาะทางไปยัง A1, A2, และ A3 เป็นไปอย่างมีประสิทธิภาพและควบคุมคุณภาพของผลลัพธ์ได้อย่างแม่นยำ

ระบบมีการสร้างกลไกที่ก้าวหน้าในการเปลี่ยนจากการประเมินเชิงคุณภาพไปสู่เชิงปริมาณผ่านการบังคับใช้ **JSON Schema ที่มีโครงสร้างตายตัว** โดยมีฟิลด์สำหรับ Severity_Rating และ Score_Deduction_Weight การทำงานนี้ทำให้ A4 สามารถสังเคราะห์ผลการวิเคราะห์จากหลายโดเมนและนำตรรกะการหักคะแนนแบบถ่วงน้ำหนักมาใช้อย่างเป็นมาตรฐาน

ข้อเสนอแนะหลักสำหรับการนำไปใช้คือการเน้นย้ำถึงความจำเป็นในการลงทุนใน **A2 Tooling Stack** โดยเฉพาะอย่างยิ่งการบูรณาการ Figma API และเครื่องมือ Computer Vision ที่เสริมด้วย WCAG Accessibility Checkers การแยกส่วนการวิเคราะห์นี้เป็นปัจจัยกำหนดความสำเร็จที่สำคัญในการรับประกันความเป็นวัตถุวิสัยของการประเมินผลหลักการ UX และ Heuristics ซึ่งเป็นส่วนที่มีน้ำหนักคะแนนสูงสุด

สุดท้ายนี้ การตรวจสอบความถูกต้องของระบบควรใช้ **Quadratic Weighted Kappa (QWK)** เป็น KPI หลักในการเปรียบเทียบมาตรฐานกับผู้เชี่ยวชาญที่เป็นมนุษย์ การใช้ QWK เป็นตัวชี้วัดความสอดคล้องจะช่วยสร้างความมั่นใจให้กับนักศึกษาและคณาจารย์ว่าผลการให้คะแนนของ AI มีความน่าเชื่อถือทางสถิติและให้ความยุติธรรมในระดับที่เทียบเท่ากับหรือสูงกว่าการประเมินโดยมนุษย์ ๐